JOÃO GUILHERME SQUINELATO DE MELO

Automatizando a Análise de Sentimentos Sobre o Noticiário Financeiro Brasileiro

São Paulo
2025

JOÃO GUILHERME SQUINELATO DE MELO

Automatizando a Análise de Sentimentos Sobre o Noticiário Financeiro Brasileiro

Monografia apresentada ao Programa de Educação Continuada da Escola Politécnica da Universidade de São Paulo, para obtenção do título de Especialista, pelo Programa de Pós-Graduação em Engenharia de Dados e *Big Data*.

São Paulo
2025

JOÃO GUILHERME SQUINELATO DE MELO

Automatizando a Análise de Sentimentos Sobre o Noticiário Financeiro Brasileiro

Monografia apresentada ao Programa de Educação Continuada da Escola Politécnica da Universidade de São Paulo, para obtenção do título de Especialista, pelo Programa de Pós-Graduação em Engenharia de Dados e *Big Data*.

Área de Concentração:

Tecnologia da Informação – Engenharia/ Tecnologia/ Gestão

Orientador:

Prof. Dr. Luiz Sergio de Souza

São Paulo
2025

Autorizo a reprodução e divulgação total ou parcial deste trabalho, por qualquer meio convencional ou eletrônico, para fins de estudo e pesquisa, desde que citada a fonte.

Catalogação-na-publicação

Squinelato de Melo, João Guilherme
Automatizando a Análise de Sentimentos Sobre o Noticiário Financeiro Brasileiro / J. G. Squinelato de Melo -- São Paulo, 2025.
50 p.

Monografia (Especialização em Engenharia de Dados e Big Data) - Escola Politécnica da Universidade de São Paulo. PECE – Programa de Educação Continuada em Engenharia.

1.Análise de Sentimentos 2.Large Langue Models 3.Mercado Acionário I.Universidade de São Paulo. Escola Politécnica. PECE – Programa de Educação Continuada em Engenharia II.t.

Dedicatória

Às minhas avós Apparecida Carli de Melo e Doralice Pereira Squinelato, aos meus pais Teresa Squinelato de Melo e Antônio José Carli de Melo, à minha irmã Ana Carolina Squinelato de Melo e à minha companheira Ingrid Silva dos Santos.

AGRADECIMENTOS

Primeiramente, agradeço aos meus pais, Teresa Squinelato de Melo e Antônio José Carli de Melo pelo fomento e incentivo aos estudos desde sempre. Além disso, agradeço à minha irmã Ana Carolina Squinelato de Melo pelos exemplos diários de resiliência e à minha companheira Ingrid Silva dos Santos pelo suporte diário.

Agradeço ao meu orientador, Prof. Dr. Luiz Sergio de Souza, por todo suporte e orientação fornecidos. Sou grato também aos meus amigos Ana Lívia Franco, Aline Mara Rudsit Bini e Marcelo Souza Pena por juntos adentrarmos e apoiarmo-nos neste curso de especialização.

Por fim, agradeço por ter tido acesso a universidades públicas, em especial à Universidade Tecnológica Federal do Paraná por minha formação sólida e, agora, à Universidade de São Paulo pela possibilidade de unir teoria à prática neste curso de especialização em Engenharia de Dados e *Big Data*.

"The original question, 'Can machines think?' I believe to be too meaningless to deserve discussion."

– Alan Turing

RESUMO

Notícias financeiras exercem certa influência sobre o mercado acionário, sobretudo no comportamento de acionistas diante momentos de incerteza, o que demonstra a importância de se analisar não apenas as oscilações das ações, mas também o fator emocional dos acionistas. Nesse cenário, a Análise de Sentimentos (AS) aplicada às notícias financeiras pode contribuir para o entendimento do mercado acionário, especialmente se realizada de forma recorrente e automatizada. Logo, o objetivo deste trabalho está em desenvolver uma aplicação automatizada capaz de extrair, transformar, armazenar e analisar diariamente os sentimentos contidos em notícias sobre empresas listadas no IBOVESPA. Ademais, para organizar os dados manipulados por este trabalho, optou-se pela arquitetura de *data lake*, a fim de segmentar em camadas, dados brutos, limpos e refinados. Já para a AS, empregou-se um LLM pré-treinado para o domínio de notícias financeiras escritas em português brasileiro. Como resultado, a aplicação obteve uma acurácia de 81% para um conjunto de teste com 93 notícias anotadas manualmente para esta avaliação. Por fim, conclui-se que o trabalho oferece uma prova de conceito para a automação da AS para o contexto do mercado acionário brasileiro, destacando o papel da engenharia de dados na transformação de dados brutos em informações úteis, com potencial para aprimoramento contínuo e adaptação a outros domínios.

Palavras-Chave – Análise de Sentimentos, *Large Langue Models*, Mercado Acionário.

ABSTRACT

Financial news exerts a notable influence on the stock market, particularly on shareholder behavior during times of uncertainty. This underscores the importance of analyzing not only stock fluctuations but also the emotional factor of shareholder. In this context, Sentiment Analysis (SA) applied to financial news can contribute to understanding the stock market, especially if performed recurrently and in an automated manner. Therefore, the objective of this work is to develop an automated application capable of daily extracting, transforming, storing, and analyzing the sentiment contained in news about companies which belongs to the IBOVESPA. Besides, a data lake architecture was chosen in order to organize raw, cleaned, and refined data into layers. For the SA, a LLM pre-trained on financial news written in Brazilian Portuguese language was employed. In addition, the application achieved an accuracy of 81% on a test set of 93 manually annotated news articles. In conclusion, this work provides a proof of concept for the automation of SA for the Brazilian stock market context, highlighting the role of data engineering in transforming raw data into useful information, with potential for continuous improvement and adaptation to other domains.

Keywords – Sentiment Analysis, Large Language Models, Stock Market.

LISTA DE FIGURAS

1 Diagrama de Fluxo de Dados 26

2 Desenho de Solução 27

3 Modelagem dos Dados 29

4 Integração e Implantação dos Recursos 30

5 Avaliação da Aplicação 35

6 Plataforma de Anotação 37

7 Matriz de Confusão 39

8 Índice de Sentimentos da Petrobras 41

9 Custos com AWS 42

LISTA DE TABELAS

1 Resumo de Trabalhos Correlatos 24

2 Métricas Obtidas pela Aplicação Proposta 39

SUMÁRIO

1 Introdução **12**

1.1 Contextualização 12

1.2 Objetivo do Trabalho 13

1.3 Metodologia 13

1.4 Visão Geral do Documento 14

2 Fundamentação Teórica **15**

2.1 Influência de Notícias no Mercado Acionário 15

2.2 Análise de Sentimentos 16

2.3 Aprendizado de Máquina 16

2.4 Modelos de Linguagem 19

2.5 Como Extrair Conhecimento dos Dados? 20

2.6 Como Lidar com Dados em Formato de Texto? 20

2.7 Trabalhos Correlatos 21

3 Desenvolvimento **25**

3.1 Arquitetura 25

3.2 Extração dos Dados 30

3.3 Limpeza e Transformação dos Dados 31

3.4 Mineração dos Dados 33

3.5 Avaliação da Aplicação Proposta 34

4 Resultados e Discussões **38**

4.1 Desempenho da Aplicação 38

4.2 Visualizando os Sentimentos 40

4.3 Custos da Aplicação 41

5 Conclusão **43**

5.1 Considerações Gerais 43

5.2 Contribuições do Trabalho 43

5.3 Principais Limitações e Dificuldades 44

5.4 Considerações Finais 44

5.5 Trabalhos Futuros 45

Referências **46**

1 INTRODUÇÃO

Este capítulo contém uma breve introdução do presente trabalho de monografia. Na sequência, a Seção 1.1 apresenta o contexto e as motivações para o desenvolvimento deste trabalho. Ademais, a Seção 1.2 disserta sobre o objetivo deste trabalho e a Seção 1.3 acerca da metodologia utilizada. Por fim, a Seção 1.4 descreve a organização dos próximos capítulos.

1.1 Contextualização

Notícias de cunho financeiro detêm certa influência quanto à tomada de decisão de acionistas que compram e vendem ações almejando prever suas flutuações, somando-se ao entendimento do mercado acionário o fator psicológico do acionista, e não apenas analises numéricas quanto as ações de empresas. Assim, compreender o sentimento das notícias sobre estas empresas pode ajudar da compreensão das flutuações de suas ações (ASHTIANI; RAAHEMI, 2023; JIN et al., 2024; SOLAIMAN et al., 2024).

Nesse sentido, a Análise de Sentimentos (AS) almeja compreender os sentimentos contidos em textos humanos, tais como noticias financeiras (SUDHA et al., 2023; MAO et al., 2024). Mesmo que imperfeito, a aplicação deste tipo de análise permite avaliar uma grade quantidade de notícias em tempo hábil, ao passo que esta mesma tarefa, se realizada por pessoas, exigiria maior tempo e esforço.

À priori, a AS era realizada por meio de abordagens manuais baseadas em dicionários léxicos, os quais associavam um sentimento fixo para as palavras. Dessa forma, determinava-se o sentimento de um texto por meio da preponderância de palavras positivas, negativas ou neutras. À posteriori, modelos de Aprendizado de Máquina (AM) foram incorporados a AS, em que características textuais eram aprendidas por meio dos dados, e não mais explicitamente determinadas pelo ser humano (MAO et al., 2024).

Ademais, com a introdução do conceito de *Large Language Model* (LLM) a AS atingiu novos patamares (CHAHAR; DUBEY, 2024; KOKAB et al., 2022; CAI et al., 2021). Destaca-se, sobretudo, a arquitetura de *transformers*, por justamente considerar tanto a ordem quanto a localização das palavras no texto, identificando a alternância de significado das palavras a partir de seu contexto (VASWANI et al., 2017).

Contudo, apesar dos avanços obtidos pelos LLMs, a maioria dos trabalhos relacionados a AS de notícias sobre o mercado acionário concentram-se na língua inglesa e, naturalmente, ao mercado acionário estadunidense (JIN et al., 2024). Além disso, carece-se de bases de notícias com o sentimento anotado para línguas não inglesas, o que obriga pesquisadores a construírem suas próprias bases de notícias (CHAHAR; DUBEY, 2024).

Nesse cenário, o presente trabalho propõe-se a somar o número de trabalhos envolvendo notícias em línguas não inglesas, em particular o português, o qual dispõe de menos recursos no campo da AS se comparado ao inglês. Motivas-se, também, pela complexidade de se desenvolver uma aplicação que englobe desde a extração até a análise dos sentimentos presentes nas notícias extraídas.

1.2 Objetivo do Trabalho

O presente trabalho tem o objetivo de desenvolver uma aplicação que extraia e analise notícias sobre o mercado financeiro brasileiro. Os objetivos específicos da aplicação são:

1. Diariamente extrair, transformar e armazenar notícias sobre empresas que participam do mercado acionário brasileiro;
2. Realizar a AS de notícias utilizando um LLM pré-treinado e de uso público.

1.3 Metodologia

Considerando o objetivo deste trabalho, optou-se por seguir a *Design Science Methodology* (DSM). Diferentemente de metodologias estritamente descritivas ou explicativas, a DSM centra-se na produção de conhecimento por meio da intervenção e da inovação, resultando no desenvolvimento de artefatos apropriados para contextos do mundo real (HEVNER et al., 2004). Assim, o valor de um artefato é mensurado não somente pela simples conformidade técnica, mas fundamentalmente por sua utilidade, eficácia e aplicabilidade em problemas reais (PEFFERS et al., 2007).

Artefatos destacam-se entre os elementos fundamentais do DSM, em que podem assumir diferentes formas: construtos (vocabulário conceitual que organiza o domínio de estudo), modelos (representações formais do problema), métodos (processos e procedimentos) e instâncias (aplicações ou sistemas implementados). Logo, por meio de um processo iterativo de *design*, avaliação e refinamento, estes artefatos são aperfeiçoados

de forma contínua. Ademais, propõe-se objetividade na avaliação dos artefatos, em que evidências empíricas podem determinar sua eficácia (PEFFERS et al., 2007).

Logo, a utilização da DSM segue um processo estruturado, composto pela: (i) identificação do problema, considerando o contexto e os *stakeholders*; (ii) definição dos objetivos de pesquisa; (iii) *design* e desenvolvimento do artefato, em consonância com metodologias específicas como, por exemplo, o *Knowledge Discovery in Databases* (KDD); (iv) avaliação sistemática do artefato; (v) iteração e refinamento; e (vi) comunicação e disseminação dos resultados (PEFFERS et al., 2007).

1.4 Visão Geral do Documento

O vigente Capítulo 1 apresentou o contexto e as motivações deste trabalho. Ainda, o capítulo caracterizou o problema no qual se insere o trabalho, bem como definiu os objetivos específicos para o desenvolvimento da aplicação proposta.

Já o Capítulo 2 elucida conceitos-chave para a realização do trabalho como, e.g., a extração de informações textuais, AM e LLMs. Além disso, o capítulo apresenta os trabalhos correlatos, descrevendo tanto o desenvolvimento como os resultados obtidos.

Ademais, o Capítulo 3 descreve o desenvolvimento dos processos de extração, armazenamento, transformação e análise das notícias. Além disso, o capítulo detalha a utilização de um LLM pré-treinado para a realização da AS, assim como especifica o processo de refinamento dos dados e, enfim, encerra explicando o processo de anotação de notícias para avaliar a aplicação proposta.

Em seguida, o Capítulo 4 apresenta os resultados obtidos por este trabalho quanto a volumetria de dados, bem como discute as métricas de acurácia, precisão, *recall* e *F1 Score* obtidas pela aplicação proposta. Complementarmente, o capítulo apresenta um *dashboard* criado a partir dos dados refinados, assim como discute os custos de operação da aplicação proposta.

Por fim, o Capítulo 5 inicia com as considerações gerais, em seguida elabora sobre as contribuições obtidas e, também, discute a respeito das principais limitações e dificuldades enfrentadas durantes o desenvolvimento deste trabalho. Enfim, o capítulo apresenta as considerações finais e se encerra comentando ideias para trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

O presente capítulo define, explica e discute conceitos essenciais para o entendimento deste trabalho da Seção 2.1 a Seção 2.6. Posteriormente, a Seção 2.7 apresenta os trabalhos correlatos, brevemente explicando seus desenvolvimentos e discutindo seus resultados.

2.1 Influência de Notícias no Mercado Acionário

Almejando conciliar a Hipótese do Mercado Eficiente (HME) - que sustenta a ideia do mercado já embutir de forma eficiente nas flutuações das ações todas as informações disponíveis - com seus críticos *behavioristas*, Lo (2004) propõe a Hipótese do Mercado Adaptativo (HMA). Mais precisamente, a HMA sustenta que o mercado, e seus acionistas, comportam-se como um ecossistema, o qual opera de forma eficiente mediante a escassez de recursos (ativos).

Em outras palavras, a principal diferença entre estas duas hipóteses é que a HMA considera que acionistas são, majoritariamente, irracionais perante o mercado por justamente estarem suscetíveis à, por exemplo, confiança exacerbada, reações exageradas, aversão à perda e, também, a influencia de pessoas ou grupos. Portanto, para Lo (2004), as emoções humanas devem ser consideradas no processo de adaptação dos acionistas em um mercado acionário, isto é, por meio de processos empíricos de tentativa e erro, os quais podem ser influenciados pelo medo de perder, mas também pela ganância de ganhar.

Sob este prisma, alguns trabalhos exploraram a influência de notícias para com o mercado acionário, evidenciando a irracionalidade de acionistas ao serem influenciados pelo noticiário financeiro tanto local quanto internacional (ASHTIANI; RAAHEMI, 2023; JIN et al., 2024). Ainda, como sustentado por Solaiman et al. (2024), uma melhor previsibilidade das flutuações do mercado acionário pode ser atingida com a análise do noticiário financeiro; corroborando a importância de analisar o sentimento contido neste tipo de noticiário consumido por acionistas diariamente.

2.2 Análise de Sentimentos

A linguagem natural constitui-se de signos (representações) que, emitidos por um aparelho vocal, transmitem infinitas possibilidades de mensagens, as quais são formadas por um número finito de elementos sonoros. A sociedade, por sua vez, figura-se como condição inerente à existência, e prevalência, da linguagem, a qual caracteriza-se por sua capacidade de ser analisada e decomposta em elementos menores (PETTER, 2002).

Neste contexto, emerge o campo do Processamento de Linguagem Natural (PLN), cujo intuito está em tornar inteligível ao computador o entendimento da linguagem natural em toda sua inerente complexidade. Para tal, obrigatoriamente, deve-se realizar, antes, a transformação do texto em uma representação numérica e, portanto, amigável ao computador. A partir disto, diversas são as formas de se extrair valor de um texto, por exemplo, com: a classificação de intenção, análise de sentimentos, busca de informações, identificação de tópicos etc (LANE; DYSHEL, 2025).

Por sua vez, a Análise de Sentimentos (AS), também conhecida como mineração de opinião, é um ramo do PLN que utiliza-se de métodos computacionais para extrair informações subjetivas de textos, i.e., sentimentos, opiniões, motivações etc. Nesse sentido, a AS pode ser empregada por empresas com o intuito de analisar suas reputações em comentários de redes sociais e textos jornalísticos (SUDHA et al., 2023).

Além disso, a AS é um tipo de classificação textual, visto que busca classificar textos por meio de rótulos (classes), tais como, positivo, negativo ou neutro (ALAMMAR; GROOTENDORST, 2024; TUNSTALL et al., 2022). A princípio, a AS era empregada por meio de regras explicitas, as quais não eram aprendidas por meio de padrões presentes nos dados de treinamento, culminando em classificações ainda limitadas. Todavia, foi com a introdução dos algoritmos de Aprendizado de Máquina (AM) que a AS galgou novos patamares (SUDHA et al., 2023; CHAHAR; DUBEY, 2024).

2.3 Aprendizado de Máquina

Como definição moderna, Géron (2025) diz que "o Aprendizado de Máquina (AM) é a ciência (e a arte) de programar computadores de modo que estes aprendam com os dados". Dessa forma, ao treinar-se um algoritmo de AM com dados textuais, obtém-se um modelo capaz, por exemplo, de classificar o sentimento (positivo, negativo ou neutro) contido em textos, os quais referenciem uma determinada empresa ou produto.

Mais especificamente, o AM é um campo da Inteligência Artificial (IA) especializado em desenvolver algoritmos capazes de aprender padrões por meio dos dados com pouca, ou nenhuma, intervenção humana. Assim, tarefas antes consideradas onerosas para seres humanos, agora podem ser realizadas em tempo hábil por meio do AM. Outras aplicações para o AM incluem: (i) predizer dados dentre um grupo finito de classes, também conhecido como classificação; (ii) predizer dados dentre uma gama de valores numéricos, regressão; (iii) tradução de textos em idiomas distintos; (iv) detecção de anomalias em dados e afins (GOODFELLOW et al., 2016).

Além disso, classifica-se o AM a depender do critério de aprendizado e avaliação utilizados durante o treinamento do algoritmo de AM. Caso disponha-se do resultado a ser predito, obtido este por supervisão humana ou oriundo do próprio ambiente, intitula-se AM supervisionado como, por exemplo, a previsão da temperatura. Do contrário, caso indisponha-se de uma supervisão, diz-se AM não supervisionado como, por exemplo, criar perfis de usuários com base em padrões de compras em um determinado *site*. Ainda, caso o aprendizado seja determinado pelo próprio empirismo, diz-se AM por reforço como, por exemplo, o treinamento de um robô aspirador (CHOWDHARY, 2020).

Ademais, após o treinamento do algoritmo de AM, é necessário avaliar o modelo resultante a fim de não só realizar um ajuste fino (otimização) ao problema que deseja-se resolver, como também testar seu desempenho perante um conjunto de dados nunca antes visto, chamado de conjunto de teste. Logo, para avaliar um modelo, compara-se a saída (classificação ou regressão) gerada pelo modelo com o valor real do dado, normalmente classificado (anotada) por serem humanos. Isto posto, as métricas mais comuns para se avaliar modelos de classificação (o que inclui a AS) são, segundo Bruce et al. (2020):

- Acurácia: métrica que consiste em calcular a proporção de classificações corretas realizadas por um modelo. Logo, na Equação 2.1, verdadeiro positivo (VP) representa a quantidade de classificações corretas de cada classe (c). Para isso, soma-se todos os acertos de cada classe (c) e divide-se este valor pela quantidade total de registros (N). Assim, obtêm-se uma medida geral, em porcentagem, sobre a assertividade do modelo, porém omitindo-se detalhes sobre a assertividade de cada classe (c). Logo, para analisar com maiores detalhes utiliza-se as métricas de precisão e *recall*;

$$acurácia = \frac{\sum_{c=1}^{n} VP_c}{N} \tag{2.1}$$

- Precisão: métrica que busca mensurar o quão preciso são as classificações de um modelo para uma determinada classe (c). Assim, na Equação 2.2, para uma deter-

minada classe (c), dividir-se a quantidade de classificações corretas (VP) pela soma entre as classificações corretas (VP) e as classificações erroneamente atribuídas a classe em questão, no que é chamado de falso positivo (FP). Logo, tem-se a precisão do modelo para uma determinada classe (c);

$$precisão_c = \frac{VP_c}{VP_c + FP_c} \tag{2.2}$$

- *Recall*: métrica que mensura a capacidade do modelo em identificar o máximo número de registros de uma determina classe (c) corretamente. Para isso, na Equação 2.3, considerando uma classe (c), basta dividir-se o número total de classificações corretas (VP) pela soma entre as classificações corretas (VP) e as classificações que foram atribuídas a outras classes, porém que, na realidade, pertenciam à classe em questão, no que é chamado de falso negativo (FN). Logo, tem-se uma medida sobre a capacidade do modelo em identificar dados de uma determinada classe (c), ou seja, quanto menor o *recall*, mais registros deixaram de ser classificados corretamente;

$$recall_c = \frac{VP_c}{VP_c + FN_c} \tag{2.3}$$

- *F1 Score*: métrica que combina a Precisão e o *Recall* em um único valor, sendo calculada a partir da média harmônica entre essas duas métricas. Logo, com a Equação 2.4, tem-se uma métrica ponderada para uma determinada classe (c), uma vez que o *F1 Score* evita interpretações parciais baseadas apenas na precisao ou *recall*. Além disso, valores de *F1 Score* próximos de 1 indicam maior equilíbrio entre Precisão e *Recall*;

$$F1_c = \frac{2 \times precisão_c \times recall_c}{precisão_c + recall_c} \tag{2.4}$$

Assim, como métrica geral comumente utiliza-se a acurácia, em que as demais métricas de precisão, *recall* e *F1 Score* avaliam especificamente cada classe (c). Todavia, para as métricas de precisão, *recall* e *F1 Score*, pode-se também calcular a média simples entre as classes (c), obtendo-se a média macro, ou então ponderar-se pela proporção de cada classe (c), obtendo-se a média ponderada.

2.4 Modelos de Linguagem

Na tentativa de propor uma nova abordagem quanto à tarefa da tradução de textos realizada por máquinas, Vaswani et al. (2017) propuseram a arquitetura de *transformers*, a qual foi capaz não só de superar o estado da arte, mas de fazê-lo reduzindo significativamente o tempo de treinamento. Para isso, a arquitetura de *transformers* apostou no mecanismo conhecido como atenção múltipla (*multi-attention*) para extrair significado contextual das palavras. Desse modo, cada *token* (palavra ou subpalavra) é interpretado a partir dos *tokens* ao redor, permitindo a arquitetura de *transformers* tanto uma melhor capacidade de interpretar (*encode*) o texto original como de gerar (*decode*) traduções.

Após a criação da arquitetura de *transformers*, surgem rapidamente outras arquiteturas explorando o mecanismo de atenção múltipla, o qual mostrou-se eficaz em outras tarefas para além da tradução realizada por máquinas. Assim, surge o *Generative pre-trained transformer* (GPT), especializando-se na tarefa de geração de texto a partir de um texto inicial, conhecido como *prompt*. Por outro lado, surge a arquitetura *Bidirectional Encoder Representations from Transformers* (BERT) com enfoque na representação textual, de modo que estas representações possam ser usadas em variadas tarefas, tais como a AS, sem que seja necessário modificar a arquitetura substancialmente (RAY, 2023; DEVLIN et al., 2018).

Assim, denomina-se *Large Laguage Models* (LLM) os modelos desenvolvidos a partir da arquiteturas de *transformers*, os quais resultam de um treinamento envolvendo um grande número de textos. Além disso, pode-se subdividir os LLMs entre dois tipos: modelos generativos, como o GPT, cujo foco está na geração de texto a partir da interação com usuários e; modelos representativos, como o BERT, cujo foco está na representação de textos para a realização de tarefas como a AS (ALAMMAR; GROOTENDORST, 2024).

Ademais, diversas versões de LLMs surgiram a partir da utilização da técnica de transferência de aprendizado (*transfer learning*), a qual possibilita desenvolver novos LLMs a partir do aprendizado obtido por modelos de referência, como o BERT (TUNSTALL et al., 2022). Desse modo, cria-se novos LLMs adaptados a contextos específicos, tais como o BERTimbau, proposto por Souza et al. (2020), adaptado para o português brasileiro e também o FinBERT-PT-BT, proposto por Santos et al. (2023), adaptado ao contexto de notícias financeiras sobre o mercado acionário brasileiro escritas em português brasileiro.

Além disso, almejando facilitar a integração entre LLMs de diferentes *frameworks*, surge a plataforma Hugging Face, disponibilizando uma API unificada para manipular

modelos e *datasets* envolvendo o PLN. Esta plataforma, portanto, não apenas viabilizou, mas também fomentou a popularização da adoção de LLMs oriundos de trabalhos acadêmicos em soluções reais (TUNSTALL et al., 2022).

2.5 Como Extrair Conhecimento dos Dados?

Aprendizado de máquina, reconhecimento de padrões, estatística e afins compartilham da mesma matéria prima: dados. Todavia, dentre diferentes metodologias, o *Knowledge Discovery in Databases* (KDD) consolidou-se como a metodologia capaz de pavimentar o processo de descoberta de conhecimento dos dados. Primeiramente, Fayyad et al. (1996) organizaram o KDD em nove etapas interativas e iterativas, as quais foram, posteriormente, sintetizadas em quatro grandes etapas por Williams e Huang (1996).

Aprofundando, na primeira etapa tem-se a seleção dos dados mais apropriados ao contexto do problema. Já na segunda etapa há o pré-processamento dos dados, os quais são limpos e processados para uma forma mais adequada. Em seguida, na terceira etapa de mineração, são aplicados algoritmos de mineração de dados a fim de se extrair informações (características) úteis. Por fim, a quarta e última etapa de avaliação encarrega-se de avaliar as características obtidas, determinando sua utilidade para com a geração de conhecimento (WILLIAMS; HUANG, 1996).

2.6 Como Lidar com Dados em Formato de Texto?

Textos, imagens, áudios e vídeos são categorizados como dados não-estruturados, uma vez que são destituídos de estrutura fixa ou definida. A princípio, este tipo de dado não era suportado por soluções de *Data Warehouses* que apenas suportavam o armazenamento de dados mediante a apresentação de um esquema. Como solução para esta problemática, em meados de 2010 surge a arquitetura de *data lake*, em essência, representando uma estratégia estrita ao armazenamento dos dados, porém adaptada para suportar altos volumes de dados, onde o processamento destes dados é realizado de forma externa, diferentemente de soluções baseadas em bancos de dados. Além disso, como boa prática, um *data lake* organiza os dados em camadas, sendo estas (SERRA, 2024):

- Camada bruta (*raw*, *bronze*): contém dados em seu estado natural, sem nenhum tipo de transformação, tal qual como foram extraídos, sendo estes mantidos imutáveis para referência histórica;

- Camada em conformidade (*conformed*, padronizada): onde todos os dados são padronizados para um mesmo formato de arquivo, normalmente otimizado para um armazenamento eficiente;
- Camada limpa (*cleansed*, *silver*, *trusted*): em que os dados são limpos e filtrados de modo que se tornem padronizados e consumíveis, respeitando certo esquema, formato, tipagem e afins;
- Camada de apresentação (*presentation*, *gold*, *refined*): local onde os dados são refinados a partir de agregações e aplicações de lógicas de negócio, a fim de que sejam, enfim, consumidos por usuários finais ou por aplicações;
- Camada *sandbox*: uma camada opcional e normalmente criada a partir de uma cópia da camada bruta, onde cientistas de dados têm liberdade para manipular e alterar dados a fim de elaborar, por exemplo, modelos de AM.

2.7 Trabalhos Correlatos

Seguindo a tendência de se empregar LLMs no contexto de notícias econômicas, Huang et al. (2024) desenvolveram um modelo de AS a partir do BERT, porém adaptado ao contexto de notícias sobre o mercado acionário chinês, gerando um modelo denominado FinBERT. Assim, ao fim do treinamento, obteve-se um LLM capaz de extrair informações sintáticas, semânticas e contextuais específicas para textos financeiros em mandarim.

Em seguida, uma camada de classificação foi anexada ao modelo FinBERT, concebendo o modelo proposto intitulado FinBERT-Sentiment, capaz de classificar o sentimento positivo ou negativo de textos financeiros em mandarim. Para tal, o modelo FinBERT-Sentiment resultou do treinamento a partir de uma base de notícias financeiras em mandarim com o sentimento anotado (classificado por humanos). Todavia, a base original totalizava 7046 notícias, número considerado baixo pelos autores, o que instigou-os a aumentarem a totalidade de notícias por meio da busca e filtragem de novas notícias. Ao fim desse processo, obteve-se 17149 notícias, das quais 12514 foram anotadas com o sentimento positivo; 4635, negativo.

Após o treinamento, o modelo FinBERT-Sentiment foi avaliado segundo as métricas de acurácia, precisão e *recall*. Além disso, o modelo FinBERT-Sentiment foi também comparado com outros três modelos oriundos de trabalhos que utilizaram a mesma base de notícias, em que o primeiro trabalho utilizou-se de um modelo BERT; o segundo, um

modelo de Rede Neural Convolucional (RNC) e; o terceiro, um modelo de *Support Vector Machine* (SVM).

Assim, analisando os resultados das métricas, viu-se que o modelo FinBERT-Sentiment pôde superar os demais modelos em todas as três métricas supracitadas, ao atingir uma acurácia de $94,52\%$, precisão de $95,26\%$ e *recall* de $93,41\%$. Por fim, os autores concluíram o trabalho associando os bons resultados obtidos não só à estratégia de aumentar a quantidade de notícias para o treinamento, mas também ao ajuste fino do modelo FinBERT-Sentiment ao contexto de notícias sobre o mercado acionário chinês.

Já no que tange a aplicação de LLMs ao contexto de notícias sobre o mercado acionário brasileiro, Santos et al. (2023) propuseram o modelo FinBERT-PT-BR, concebido a partir de uma versão brasileira do BERT, conhecida como BERTimbau, realizando um ajuste fino deste ao contexto de textos oriundos de notícias financeiras publicadas em português brasileiro sobre o mercado acionário brasileiro.

Posteriormente, os autores anexaram uma camada de classificação de sentimentos ao modelo FinBERT-PT-BR, criando assim um modelo capaz de realizar a AS, batizando-o de SentFinBERT-PT-BT. Mais especificamente, os autores treinaram o classificador de sentimentos com base num conjunto de $1,4$ milhão de notícias financeiras, as quais foram extraídas de três veículos de comunicação (Valor Econômico, Exame e Infomoney), sendo estas publicadas entre 2006 a 2022.

Após isso, dentre todas as notícias coletadas, os autores selecionaram aleatoriamente 503 notícias e manualmente anotaram-nas de acordo com o sentimento (positivo, negativo ou neutro) contido nas notícias. Assim, o modelo SentFinBERT-PT-BT foi avaliado por meio destas 503 notícias, obtendo uma acurácia de 76% e *F1 Score* de 73%, superando o modelo BERTimbau, no qual foi originalmente baseado, para o contexto da AS de notícias financeiras escritas em português brasileiro.

Em seguida, a partir de uma amostra de notícias, gerou-se uma série temporal a partir das classificações do modelo SentFinBERT-PT-BT, em que subtraiu-se o número de notícias classificadas como negativas das positivas e dividiu-se o resultado desta subtração pelo total de notícias compreendidas em um intervalo temporal, e.g., mensal, semanal ou diário. Também conhecida como índice de sentimentos, esta série temporal normaliza os sentimentos ao longo de um intervalo temporal, limitando os valores entre -1 (máximo valor negativo) e 1 (máximo valor positivo).

Ademais, a fim de testar a utilidade do índice de sentimentos, os autores simularam, a partir da série histórica de preços do Índice da Bolsa de Valores de São Paulo

(IBOVESPA), apostas em ações cuja correlação entre o índice de sentimentos e o preço da ação era altamente negativa, ou seja, apostaram na valorização de ações cujo preço crescia, ao passo que o índice de sentimentos descia. Batizada de "apostando contra o sentimento", esta estratégia considera que acionistas inseguros, e altamente influenciados por notícias negativas, vendem ações que não necessariamente são desvalorizadas por notícias negativas, e sim por fatores macroeconômicos.

Como resultado, a estratégia "apostando contra o sentimento" apresentou um retorno de investimento acumulado $2,7$ vezes maior ante ao retorno de investimento base esperado pelo IBOVESPA, o que denota as vantagens que podem ser obtidas com a AS de notícias financeiras sobre o mercado acionário brasileiro.

Agora, no que tange ao contexto de notícias financeiras escritas em inglês, Duan et al. (2024) propusera um modelo de AS de notícias sobre o mercado acionário estadunidense, batizando-o de LFBP. Este modelo foi arquitetado por meio da combinação de diferentes técnicas de AM, no que é conhecido como Aprendizado Híbrido (AH).

Para tal, os autores utilizaram de uma modificação do algoritmo de *Latent Dirichlet Allocation* (LDA), integrando-o com o *K-Nearest Neighbors* (KNN), a fim de anexar ao modelo LFBP informações sobre os tópicos (temas) das notícias em análise. Além disso, a fim de extrair informações contextuais, um modelo FinBERT ajustado à língua inglesa foi escolhido pra ser anexado à arquitetura do modelo LFBP.

Ademais, fez-se o uso do *Bidirectional Gated Recurrent Unit* (BiGRU) com o intuito de extrair informações temporais dos textos. Por fim, a última camada do modelo LFBP aplicou um balanceamento dinâmico quanto a atenção (importância) das palavras para, assim, auxiliar na identificação do sentimento de um texto.

Já para o treinamento da arquitetura LFBP, foram utilizadas cinco bases de notícias escritas em inglês com o sentimento anotado, contemplando textos oriundos de noticiários especializados e redes sociais relativos ao mercado financeiro estadunidense. Assim, duas bases distintas de notícias, totalizando 4009 textos, foram utilizadas para o treinamento e ajuste fino, culminando no modelo LFBP. Já para a avaliação do modelo LFBP, as três bases remanescentes foram utilizadas, somando 18970 textos.

Já quanto aos resultados obtidos, o modelo LFBP obteve uma acurácia de $94,70\%$, superando sistematicamente os outros sete modelos testados pelos autores. Sob outra perspectiva, em relação a AS obtida estritamente pelo modelo FinBERT, o modelo LFBP demonstrou-se $7,27\%$ melhor quanto à métrica de *F1 Score*.

Com o intuito de resumir os trabalhos correlatos supracitados, a Tabela 1 apresenta os trabalhos, modelos, conjuntos de dados e acurácias obtidas pelos três trabalhos discutidos anteriormente.

Tabela 1: Resumo de Trabalhos Correlatos

Trabalho	**Modelo**	**Conjunto de Dados**	**Acurácia**
Huang et al. (2024)	FinBERT-Sentiment	notícias em mandarim sobre o mercado acionário chinês	$94,52\%$
Santos et al. (2023)	SentFinBERT-PT-BR	notícias em português sobre o mercado acionário brasileiro	$76,00\%$
Duan et al. (2024)	LFBP	notícias e *tweets* em inglês sobre o mercado acionário estadunidense	$94,70\%$

3 DESENVOLVIMENTO

O presente capítulo descreve o desenvolvimento da aplicação proposta por este trabalho de monografia, em que as seções a seguir apresentam, progressivamente, detalhes sobre os processos realizados desde a extração de dados brutos até a apresentação de dados refinados. Assim, até o fim deste capítulo, terá-se uma compreensão detalhada sobre como automatizar a AS de notícias sobre o mercado acionário brasileiro.

Mais exatamente, a Seção 3.1 detalha a arquitetura de *data lake* projetada para organizar e armazenar os dados em camadas, de modo a contemplar o ciclo de vida dos dados desde sua forma bruta até sua forma mais refinada. Na sequência, a Seção 3.2 demonstra como foram extraídas as notícias sobre o mercado acionário brasileiro, bem como os dados sobre as empresas listadas na bolsa de valores brasileira, a Brasil, Bolsa, Balcão (B3).

Posteriormente, a Seção 3.3 explica como os dados foram limpos e transformados a fim de facilitar a mineração de características relevantes das notícias, isto é, do sentimento contido nas notícias. Posteriormente, a Seção 3.4 apresenta como a AS foi realizada por meio de um LLM pré-treinado e, em seguida, a Seção 3.5 descreve o processo de seleção e anotação de um conjunto de notícias para avaliar a assertividade da aplicação proposta.

3.1 Arquitetura

Como representação agnóstica e desatrelada de tecnologias, a Figura 1 ilustra o diagrama do fluxo dos dados extraídos, transformados, armazenados e minerados por este trabalho de monografia. Assim, de cima para baixo os dados fluem de um estado bruto até um estado mais refinado, por meio de uma sucessão de etapas baseadas no KDD.

Alternativamente, com a Figura 2, tem-se o desenho de solução, o qual representa as tecnologias da *Amazon Web Services* (AWS) utilizadas, bem como suas integrações. Assim, na parte superior da Figura 2 encontra-se a orquestração dos processos que têm execução diária. Desse modo, todos os dias às 03:00 UTC[1], por cerca 15 minutos, a orquestração destes processos é realizada por meio de uma AWS Step Function.

[1] O *Coordinated Universal Time* (UTC) representa um fuso horário padrão para se coordenar o tempo no mundo, em que o fuso horário de brasília se encontra a -3:00 horas defasadas em relação a UTC.

Figura 1: Diagrama de Fluxo de Dados

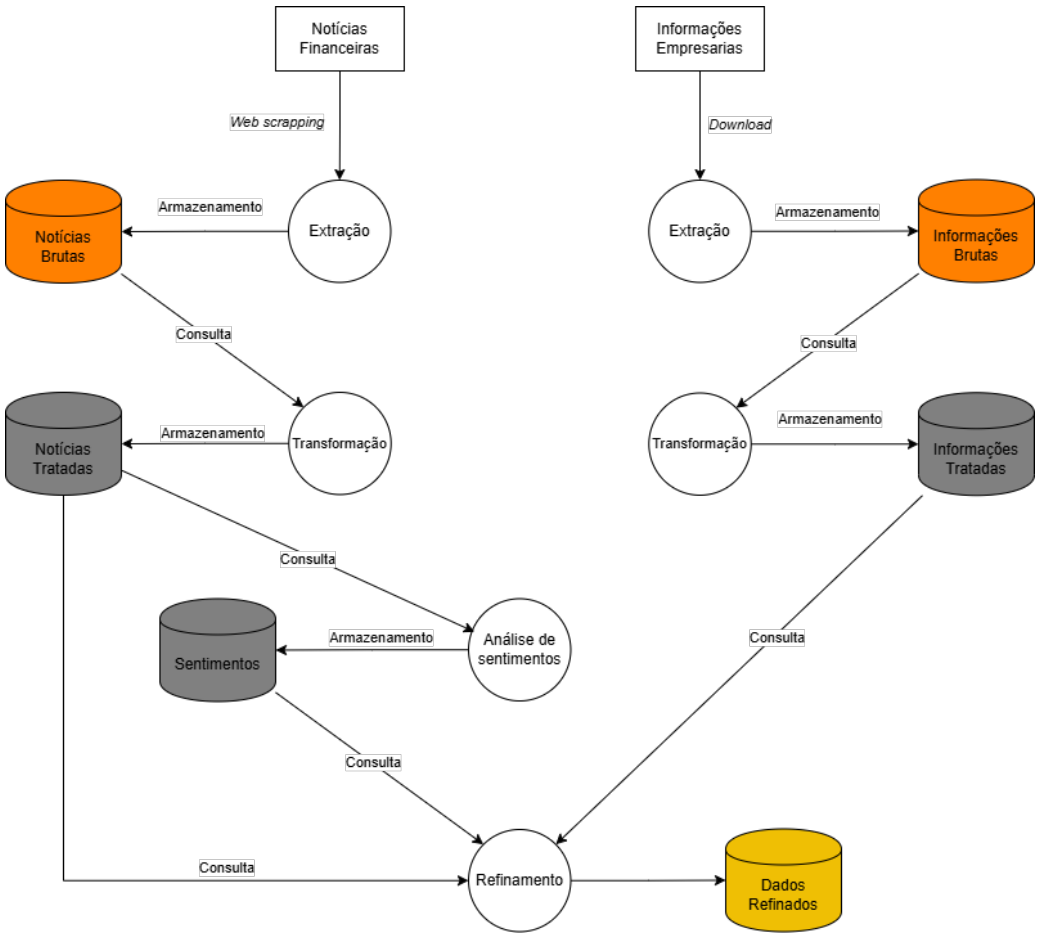

Fonte: Autoria Própria

Em seguida, os processos orquestrados pela AWS Step Function armazenam os dados processados em um *data lake*, o qual encontra-se no cerne da Figura 2. Particularmente, dá-se o nome de *data lake* ao espaço onde os dados estruturados e não-estruturados são armazenados como arquivos, em que para este trabalho o AWS S3 foi utilizado como serviço de armazenamento escalável e econômico. Além disso, visando separar logicamente os dados, quatro camadas de dados foram criadas, sendo estas:

- Camada *raw*, ou bronze: camada em que os dados são armazenados em sua forma bruta (*raw*), sem qualquer tipo de tratamento ou formatação;
- Camada *trusted*, ou prata: camada responsável por armazenar dados em um estado mais confiável (*trusted*), por exemplo, com nomes de colunas padronizados, dados duplicados removidos, conversão de tipagem etc;
- Camada *refined*, ou ouro: camada em que os dados são refinados (*refined*) de modo a apresentar maior valor ao unir e agrupar dados da camada *trusted*;

Figura 2: Desenho de Solução

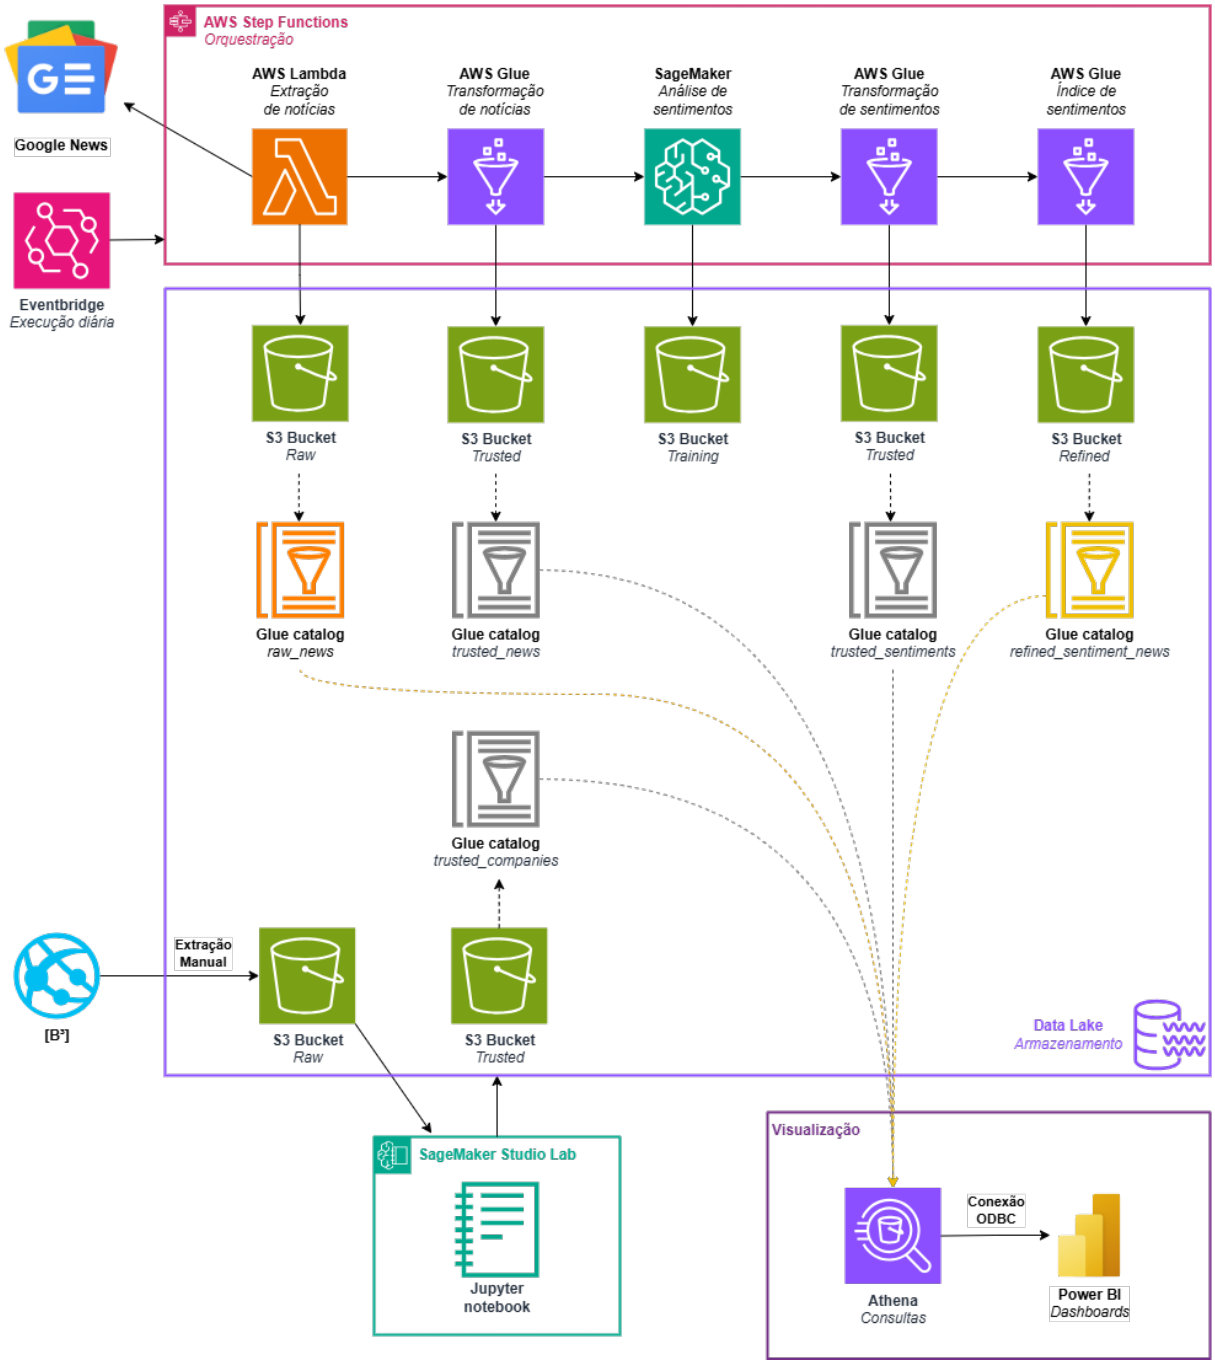

Fonte: Autoria Própria

- Camada *training*: camada criada para armazenar dados oriundos da AS de notícias, assim como para dar suporte ao processo de anotação de notícias e, também, a avaliação da aplicação proposta.

Assim, todas as camadas citadas organizam-se em *buckets* (análogo a pastas em um sistema de arquivos) distintos no AWS S3, os quais, majoritariamente, armazenam os da-

dos no formato parquet[1]. Além disso, as camadas *raw*, *trusted* e *refined* foram catalogadas no AWS Glue Catalog, o qual cria uma interface SQL para consultar os dados por meio do serviço AWS Athena.

Já na parte inferior esquerda da Figura 2, encontra-se a ingestão manual, e pontual, de dados sobre empresas listadas na B3, os quais são processados por um *script* Python executado em um Jupyter notebook hospedado no AWS SageMaker Studio Lab e, enfim, armazenados na camada *trusted*. Além disso, na parte inferior direita da Figura 2 está ilustrado como os dados presentes no *data lake* são acessados pelo AWS Athena e, enfim, importados para o Power BI Desktop, via conexão ODBC[2], para a geração de um *dashboard* demonstrativo.

Ademais, a Figura 3 representa a modelagem criada para organizar os dados em tabelas e camadas, de modo a facilitar a consulta e exploração dos dados. Posteriormente, nas seções seguintes, todas as tabelas ilustradas na Figura 3 serão detalhadas.

Além isso, a fim de realizar testes locais antes de implantar a arquitetura proposta, utilizou-se um *laptop* Acer Nitro 5 equipado com um processador i5 9300H e 24GB de memória RAM. Assim, testes locais foram realizados via Docker para conteinerizar AWS Lambdas e AWS Glues, poupando custos e acelerando o processo de correções de problemas. No entanto, alguns processos que não puderam ser testados localmente, foram testados por meio do AWS SageMaker Studio Lab, o qual fornece uma plataforma para executar *scripts* Python por meio de Jupyter notebooks por um preço acessível.

Já quanto a implantação do trabalho, a infraestrutura em nuvem da AWS foi utilizada, em que os recursos AWS contidos na Figura 2 foram criados via AWS CloudFormation, viabilizando a organização e replicabilidade deste trabalho em ambientes AWS. Já quanto a visualização dos dados, optou-se pelo Power BI Desktop, uma vez que esta versão não representa custos adicionais para este trabalho de monografia.

Enfim, todos os *scripts* necessários para a construção deste trabalho foram salvos e versionados em um repositório privado no Github. Assim, com a Figura 4 tem-se a representação de como foi realizada a integração e implantação dos recursos explorados por este trabalho de monografia.

[1] O formato de arquivo parquet é uma iniciativa Apache, cujo foco está em armazenar dados de forma eficiente e compacta, também otimizado para a leitura de dados.

[2] O *Open Database Connectivity* (ODBC) é um padrão de interface para bancos de dados, cujo foco está na portabilidade e execução em diferentes linguagens de programação, bancos de dados e sistemas operacionais.

Figura 3: Modelagem dos Dados

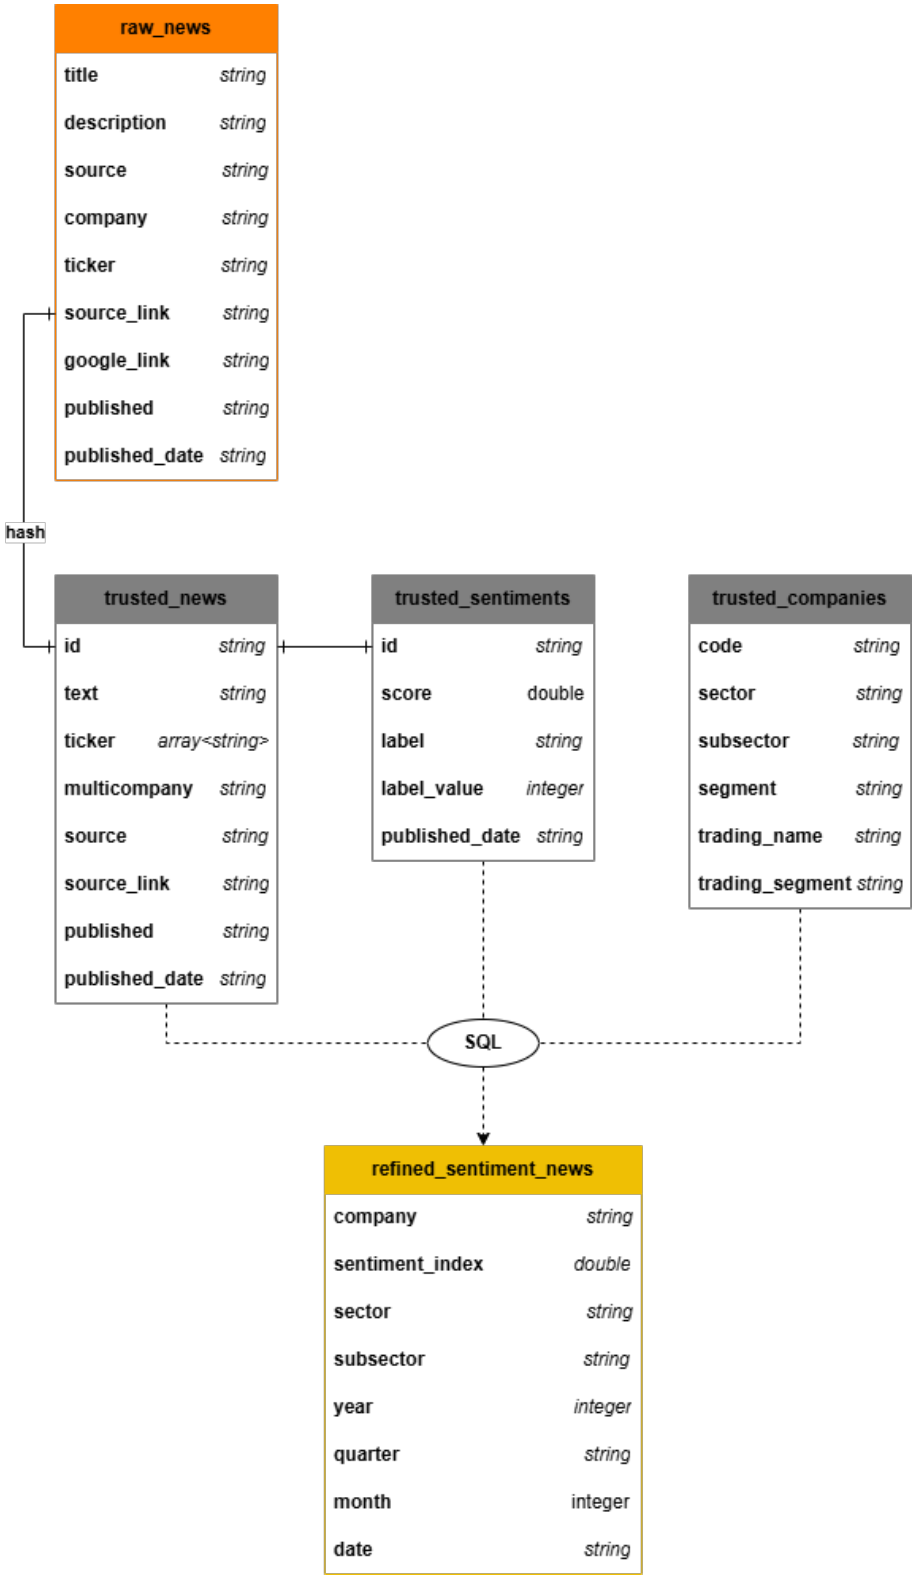

Fonte: Autoria Própria

Figura 4: Integração e Implantação dos Recursos

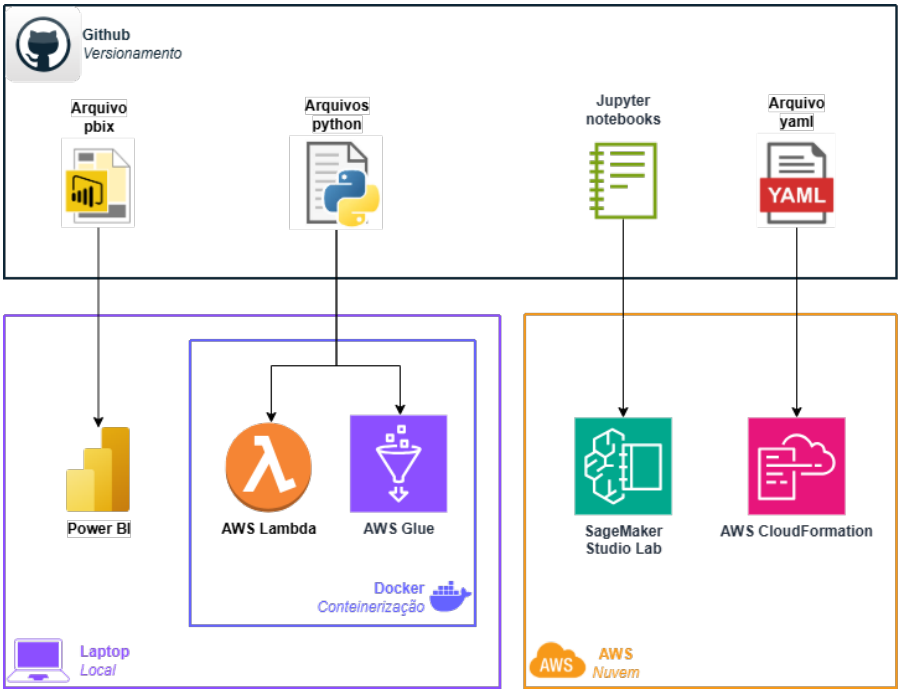

Fonte: Autoria Própria

3.2 Extração dos Dados

Esta seção descreve o processo de extração de todos os dados utilizados por este trabalho de monografia, os quais são armazenados na camada *raw*. Inicialmente, em relação as notícias sobre o mercado acionário brasileiro, filtrou-se por notícias de empresas presentes na carteira de investimentos do IBOVESPA referente ao dia 23 de janeiro de 2025. Isto resultou na seleção 87 empresas e seus respectivos *tickers*[1].

Em seguida, o portal de notícias Google News foi escolhido como fonte de pesquisa de notícias financeiras, justamente por sua capacidade de agregar notícias de diferentes portais de notícias disponíveis na Internet, tais como, E-Investidor, Money Times, Info-Money, Finance News, Istoé Dinheiro, Valor Econômico e afins. Mais especificamente, a biblioteca pygooglenews foi utilizada como interface entre o Google News e a linguagem de programação Python.

Assim, automatizou-se o processo de pesquisa por notícias sobre cada uma das 87 empresas previamente selecionadas; em que são extraídas apenas notícias que mencionem explicitamente o *ticker* dessas empresas no título das notícias. Logo, de cada notícia extraída, os seguintes dados são selecionados: *link* para a notícia no Google News; título;

[1] O *ticker* é um código de negociação que representa as ações de uma empresa como, por exemplo, o *ticker* "PETR4", que representa a empresa Petrobras.

empresa mencionada; *ticker*, a fonte (site de origem) e data de publicação da notícia.

Entretanto, apesar da conveniência ofertada pelo Google News em agregar diversos portais de notícias, qualquer informação extra das notícias extraídas exige que o *link* original seja acessado, o que foi possível por meio da biblioteca googlenewsdecoder. Então, uma vez tendo acesso à notícia na íntegra, a biblioteca BeaultifulSoap foi empregada a fim de extrair-se descrições breves sobre as notícias, oriundas de *tags* do código HTML onde as notícias são publicadas.

Logo, para abarcar toda a lógica supracitada, um AWS Lambda em Python foi criado para extrair as notícias das últimas 24 horas a partir da inicialização desta AWS Lambda. Porém, como o AWS Lambda em questão exigia maior poder computacional, necessitou-se registrar uma imagem Docker no AWS ECR contendo o *script* Python a ser executado pelo AWS Lambda. Isto permite aumentar a RAM e o espaço reservado para a instalação de bibliotecas pesadas como, por exemplo, o Pandas para a manipulação de dados.

Para orquestrar este processo, o AWS EventBridge foi utilizado para disparar todos os dias às 03:00 UTC um AWS Step Function, o qual tem como primeira etapa justamente inicializar o supracitado AWS Lambda. Notícias são então coletadas diariamente, formando a tabela intitulada `raw_news`, a qual armazena em forma de colunas todos os dados anteriormente mencionados.

Além disso, para obter-se dados sobre quais são os setores, subsetores, segmentos e afins de cada uma das 87 empresas monitoradas por este trabalho, coletou-se manualmente estes dados a partir do *site* oficial da B3. O arquivo xlsx[1] contendo informações sobre as 381 empresas listadas na B3, referente a setembro de 2025, foi então manualmente baixado e salvo na camada *raw*.

3.3 Limpeza e Transformação dos Dados

A presente seção descreve como foi realizada a limpeza e transformação dos dados utilizados por este trabalho de monografia, os quais são armazenados na cama *trusted*. Assim, logo após a extração e armazenamento das noticias na camada *raw*, a orquestração criada a partir do AWS Step Function se encarrega de iniciar o processo de *Extract, Transform and Load* (ETL) por meio de um AWS Glue, o qual utiliza o PySpark para o processamento distribuído e otimizado dos dados.

Em maior detalhe, este AWS Glue encarrega-se de ler as noticias da camada *raw*

[1] O formato xlsx é utilizado para armazenar planilhas do Microsoft Excel.

por meio do AWS Glue Catalog. Além disso, esse processo de leitura é otimizado pelo AWS Glue Bookmark, o qual encarrega-se de memorizar quais partições já foram lidas e processadas até então, o que faz com que o AWS Glue acesse apenas notícias ainda não processadas, evitando reprocessamentos desnecessários.

Em seguida, filtra-se pelas notícias cujos *links* originais puderam ser extraídos e, em seguida, gera-se um *hash*[1], por meio do algoritmo SHA-256, criando-se assim um identificador (`id`) para as notícias. Desse modo, com o então criado `id`, tem-se uma forma rápida e compacta de identificar as notícias processadas.

Ademais, como o escopo deste trabalho limita-se à AS unitária, isto é, que atribui a cada notícia apenas um único rótulo de sentimento (positivo, negativo ou neutro), viu-se a necessidade de se diferenciar as notícias que mencionam múltiplas empresas, daquelas que mencionam apenas uma.

Para isso, a fim de eliminar as notícias repetidas (deduplicação) e identificar notícias que mencionam múltiplas empresas, aplicou-se o agrupamento por `id`. Desse modo, agrupou-se as notícias que foram extraídas de forma repetida, devido a mencionarem mais de uma, dentre as 87, empresas de interesse. Assim, manteve-se apenas uma notícia por `id`, em que os *tickers* identificados foram armazenados como lista na coluna `ticker`.

Não obstante, mesmo com a deduplicação, algumas notícias ainda mencionam *tickers* de empresas não pertencentes as 87 empresas selecionadas para este trabalho. Logo, viu-se a necessidade de buscar, via expressão regular, por *tickers* presentes tanto no título quanto na descrição da notícia, somando-os à coluna `ticker`. Em seguida, criou-se uma coluna booleana chamada `multicompany`, a qual recebe o valor verdadeiro caso a coluna `ticker` tenha mais de um *ticker*; do contrário, falso.

Além disso, outras transformações foram realizadas a fim de remover ruido textual, isto é, informações que nada têm a agregar, tais como: as mensagens de falha ao extrair a descrição de uma notícia; a menção à fonte da notícia concatenada ao fim do título; remoção de espaços em branco, tabulação, quebra de linha, caracteres especiais. Ainda, para facilitar o processamento do texto para a AS, uniu-se o título e a descrição em uma única coluna chamada `text`.

Logo, todas as transformações mencionadas anteriormente culminaram na tabela `trusted_news` presente na camada *trusted*, sendo esta tabela particionando pela data de publicação da notícia. Assim, todas as transformações supracitadas são realizado por

[1] *Hash* comumente se refere a algoritmos capazes de gerar uma representação de tamanho fixo e irreversível, como um código, a partir de uma entrada de tamanho variado.

um AWS Glue, o qual é inicializado pelo AWS Step Function logo após a ingestão de notícias na camada *raw*.

Ademais, os dados relativos às empresas foram igualmente transformados da camada *raw* para a camada *trusted*, resultando na tabela `trusted_companies`, a qual agrupa informações sobre o setor, subsetor, segmento, nome de negociação, código da empresa (prefixo dos *tickers*) e o segmento de negociação das empresas listadas na B3. Todavia, devido a baixa frequência de atualização e simplicidade quanto a transformação dos dados, optou-se por realizar este processo via *script* Python em um Jupyter notebook hospedado no AWS SageMaker Studio Lab.

3.4 Mineração dos Dados

Nesta seção descreve-se o processo de mineração dos dados, que no contexto deste trabalho de monografia refere-se à análise do noticiário especializado no mercado acionário brasileiro, a fim de se extrair o sentimento presente nas notícias extraídas. Para isso, fez-se uso do modelo SentFinBERT-PT-BR, um LLM pré-treinado para o contexto de notícias escritas em português brasileiro sobre o mercado acionário brasileiro. Assim, o modelo foi importado já pronto da plataforma Hugging Face e, posteriormente, registrado no Amazon SageMaker AI a fim de ser utilizado em inferências[1] em *batch*[2], as quais consomem menos recursos computacionais.

Contudo, em detrimento da facilidade ofertada na importação e utilização de LLMs na AWS, é necessário adaptar as notícias a serem inferidas para o formato JSON[3], mantendo-se apenas o texto a ser inferido e o `id` da notícia, em que cada registro deve ser separado por uma quebra de linha. Logo, após a execução da inferência em *batch* das notícias, o Amazon SageMaker AI retorna os dados igualmente no padrão recebido, porém contendo a inferência do texto de acordo com o padrão estipulado pelos autores do LLM.

Em vista disso, necessitou-se de mais um AWS Glue responsável por justamente transformar (pós-processar) as inferências do LLM em uma tabela consultável e padronizada na camada *trusted*, nascendo assim a tabela `trusted_sentiments`. Mais especificamente, esta tabela contém dados sobre o sentimento positivo, negativo ou neutro das notícias,

[1] O processos de inferir um dado significa solicitar a algum modelo de AM que determine uma classe ou um valor para um determinado dado como, por exemplo, determinar o sentimento de um texto.

[2] O processamento em *batch*, ou lote, consiste em agrupar conjuntos de dados e processá-los de uma única vez, ao invés de constantemente processá-los, tal como seria no processamento em tempo real.

[3] O *JavaScript Object Notation* (JSON) é um formato de texto criado para representar dados de forma inteligível a seres humanos.

assim como a representação numérica do sentimento, respectivamente, 1, -1 e 0, além da data de publicação, `id` da notícia e, enfim, o *score*, ou confiança, do LLM para com o sentimento inferido.

Além disso, estes processos de inferência em *batch* e de pós-processamento foram igualmente agendados via AWS Step Function, sendo inicializados imediatamente após a ingestão das notícias transformadas na tabela `trusted_news`. Além disso, estes processos são apenas realizados para novas notícias, o que evita a inferência e pós-processamento desnecessários de notícias já processadas.

Posteriormente, a fim de refinar os dados até então extraídos e transformados na camada *trusted*, criou-se mais um AWS Glue, orquestrado via AWS Step Function, responsável por unir as tabelas `trusted_companies`, `trusted_news` e `trusted_sentiments` para formar a tabela `refined_sentiment_news` na camada *refined*.

Para isso filtrou-se pelas notícias que citam apenas uma empresa, pois analisar notícias que citam múltiplas empresas exigiria processos fora do escopo deste trabalho. Além disso, dos *tickers* foram extraídos os códigos de negociação das empresas, por exemplo, de "PETR3" e "PETR4", extraiu-se "PETR" para se referir a Petrobras, a fim de agrupar os sentimentos por empresa. Ademais, apenas notícias inferidas com mais de 50% de confiança (*score*) pelo LLM utilizado foram consideradas.

Após isso, para cada empresa, o índice de sentimentos foi calculado subtraindo-se a quantidade de notícias negativas das positivas, e dividindo o resultado desta subtração pelo total de notícias positivas, negativas e neutras dentro de um intervalo temporal diário. Desse modo, tem-se uma forma normalizada de se acompanhar a flutuação diária de sentimentos em relação a uma empresa, em que o número 1 representa a máxima positividade; -1, máxima negatividade; 0, neutralidade.

Enfim, dados sobre o setor, subsetor, segmento e nome das empresas, assim como informações temporais sobre o ano, semestre, mês e dia foram adicionados como informações úteis à tabela. Desse modo, somando-se todos os processos mencionados acima, criou-se a tabela `refined_sentiment_news`.

3.5 Avaliação da Aplicação Proposta

Apesar do LLM utilizado já ter sido avaliado pelos autores, optou-se por uma avaliação da aplicação proposta como um todo, uma vez que as notícias aqui trabalhadas contemplam veículos de comunicação diferentes dos utilizados no desenvolvimento do LLM

empregado. Além disso, as notícias coletadas por este trabalho citam explicitamente empresas e seus *tickers*, não contendo notícias genéricas sobre o mercado acionário em si, mas sim sobre as empresas que nele negociam suas ações. Diante disso, almejando averiguar a eficácia da aplicação proposta para a AS de notícias sobre o mercado acionário brasileiro, desenvolveu-se um processo de avaliação, representado pela Figura 5, a partir de recursos disponibilizados pelo AWS SageMaker AI.

Figura 5: Avaliação da Aplicação

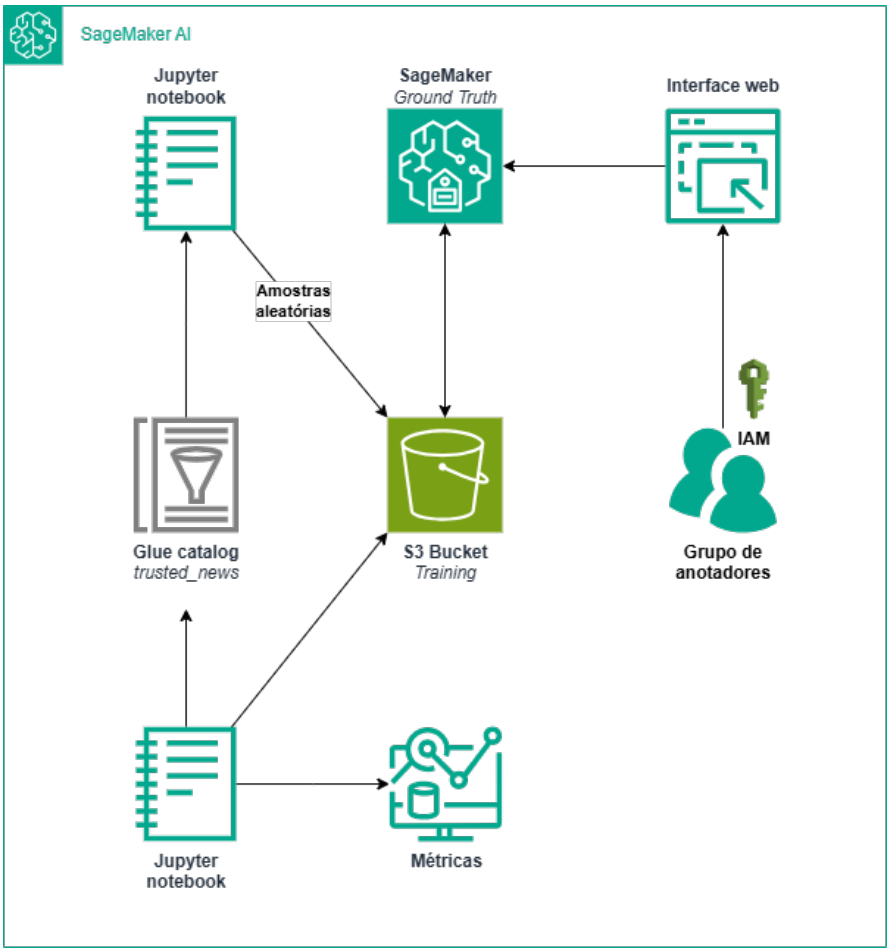

Fonte: Autoria Própria

A princípio, selecionou-se aleatoriamente um conjunto de 125 notícias por meio de um *script* Python executado em um Jupyter notebook hospedado no AWS SageMaker Studio Lab, em que este conjunto de notícias foi extraído da tabela `trusted_news`, transformado em um arquivo JSON e salvo no *bucket* S3 *training*. Ainda, para que este conjunto de notícias pudesse ser processado pelo serviço de anotação[1] da AWS, conhecido como *Groud Truth*, adaptações foram necessárias.

[1]A anotação de dados é o nome dado ao processo que consiste em empregar pessoas à tarefa de classificar dados dentre de um conjunto de categorias.

Mais precisamente, o texto apresentado aos anotadores dentro do serviço *Groud Truth* não pode conter quebra de linha e também deve conter no próprio texto seu identificador (`id`) para que assim possa ser identificado ao fim do processo de anotação. Desse modo, o *Groud Truth* atua como um serviço que gerencia a anotação de dados (textos, imagens etc), em que permite-se escrever instruções para facilitar o entendimento do processo de anotação. Também, deve-se definir os rótulos (classes) permitidos para a anotação, em que para este trabalho de monografia estipulou-se os rótulos "positivo", "negativo", "neutro" e, adicionalmente, o rótulo "inconclusivo" para que anotadores indecisos não enviesassem a avaliação com rótulos incertos.

Já no que tange ao gerenciamento de pessoas para a tarefa de anotação, o *Groud Truth* permite a criação de grupos de privados de anotadores, assim como a possibilidade de formar grupos públicos de anotadores, pagando-se por cada anotação realizada. No entanto, assim que uma pessoa inicia uma tarefa de anotação, o *Groud Truth* define um tempo máximo de 8 horas para cada anotador finalizar sua tarefa, bem como define um tempo máximo de 30 dias para se finalizar o processo de anotação, isto é, até que cada texto seja anotado pela quantidade mínima de anotadores estipulados por texto.

É importante salientar que caso o anotador não termine uma tarefa de anotação em 8 horas, todo progresso é perdido e a tarefa deve ser refeita. Em vista disso, para facilitar o processo de anotação, o conjunto de 125 notícias foi subdividido em 6 subconjuntos menores contendo 25 notícias cada. Assim, cada um dos 6 subconjuntos representa uma tarefa de anotação isolada para o *Ground Truth* que gerencia o processo de anotação.

Com as tarefas criadas no *Ground Truth*, estas foram atribuídas a anotadores por meio de um grupo privado, em que a partir do e-email dos integrantes, a AWS encarrega-se de enviar um e-mail contendo as instruções de acesso à interface *web* providenciada pelo *Ground Truth* para realizar o processo de anotação. Contudo, os integrantes do grupo privado recebem apenas os mínimos privilégios à conta AWS em questão para realizar a anotação, o que é gerenciado pelo AWS IAM. Dito isto, o grupo privado utilizado neste trabalho monografia constituiu-se apenas do próprio autor deste trabalho.

Ademais, a Figura 6 ilustra a interface *web* providenciada pelo *Ground Truth* para apresentar as notícias durante o processo de anotação. Dessa forma, as tarefas de anotação previamente definidas são gerenciadas de forma isolada pelo serviço de *Ground Truth*.

Posteriormente, ao fim do processo de anotação, o *Groud Truth* gera arquivos JSON com as anotações consolidadas entre os anotadores envolvidos no processo de anotação. Desse modo, outro *script* Python executado em um Jupyter notebook hospedado no AWS

Figura 6: Plataforma de Anotação

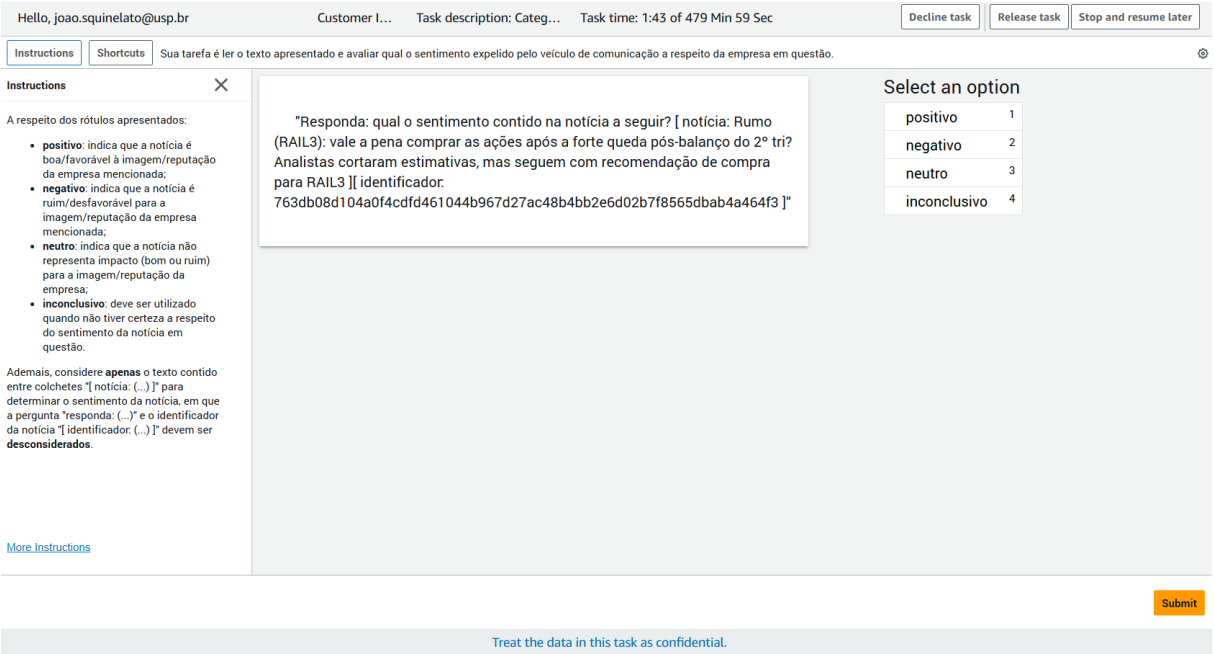

Fonte: Autoria Própria

SageMaker Studio Lab foi utilizado para interpretar estes aquivos. Assim, ao interpretar todos os arquivos JSON, obteve-se o rótulo de cada uma das 125 notícias selecionadas para avaliar a aplicação proposta. Todavia, das 125 notícias, 32 destas foram anotadas com o rótulo "inconclusivo" e, portanto, foram desconsideradas da avaliação.

Enfim, com o conjunto remanescente de 93 notícias, criou-se mais um *script* Python executado em um Jupyter notebook hospedado no AWS SageMaker Studio Lab para obter as métricas de acurácia, precisão, *recall* e *F1 Score*. Assim, por meio do `id` das notícias, pôde-se comparar a inferência do sentimento obtida pela aplicação proposta com o sentimento oriundo da anotação humana, cujos resultados das métricas encontrar-se-ão no próximo capítulo.

4 RESULTADOS E DISCUSSÕES

Este capítulo discute os resultados obtidos neste trabalho de monografia, os quais contemplam a volumetria de dados, assim como as métricas obtidas pela aplicação proposta para a AS das notícias. Ademais, apresenta-se um *dashboard* como exemplo de utilização dos dados refinados e discute-se os custos envolvidos durante o desenvolvimento e implantação deste trabalho.

4.1 Desempenho da Aplicação

Tendo em vista a modelagem de dados apresentada no Capítulo 3, diariamente obtêm-se em média 80,40±55,06 notícias na tabela `raw_news`, as quais são reduzidas a uma média de 63,10 ± 48,52 notícias na tabela `trusted_news`, após a deduplicação. Além disso, cerca de 23,15% das notícias são desconsideradas da tabela `refined_sentiment_news` por mencionarem mais de uma empresa em seu texto, o que está além dos objetivos deste trabalho quanto a AS. Também, cerca de 10,74% das noticias são desconsideradas da tabela `refined_sentiment_news`, por possuírem um *score* menor que 50% para com as inferências do LLM utilizado.

Já quanto ao desempenho da AS realizada pela aplicação proposta, após avaliá-la perante o conjunto de teste, contendo este 93 notícias, obteve-se uma acurácia de 81%. Especificamente, na Figura 7, tem-se a matriz de confusão que representa todas as 93 notícias utilizadas na avaliação, em que as linhas representam os sentimentos anotados e as colunas os sentimentos classificados pela aplicação proposta. Assim, a diagonal principal da Figura 7 representa o número de notícias que foram classificadas corretamente para cada sentimento. Em contrapartida, as demais células da matriz representam erros, destacando-se a imprecisão para com as notícias neutras. Posteriormente, a partir desta matriz de confusão, calculou-se as métricas representadas pela Tabela 2.

Figura 7: Matriz de Confusão

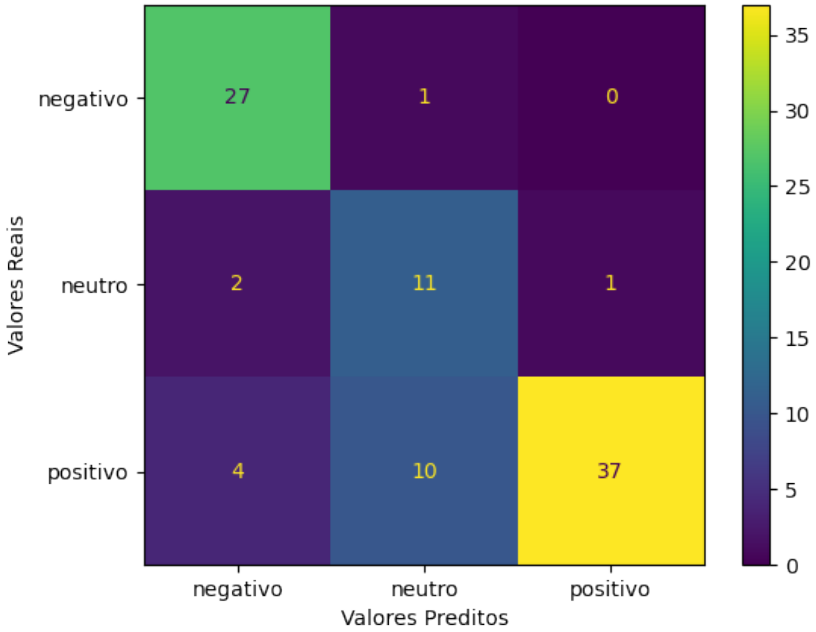

Fonte: Autoria Própria

Tabela 2: Métricas Obtidas pela Aplicação Proposta

Sentimento	**Precisão**	***Recall***	***F1 Score***	**Proporção**
Negativo	82%	96%	89%	30,10%
Neutro	50%	79%	61%	15,05%
Positivo	97%	73%	83%	54,85%
Média Macro	76%	83%	78%	100%
Média Ponderada	86%	81%	81%	100%

Vê-se com a Tabela 2 as métricas de precisão, *recall* e *F1 Score* para cada um dos sentimentos, em que a coluna proporção expressa a porcentagem de notícias positivas, negativas e neutras no conjunto de teste. Além disso, percebe-se um desbalanceamento entre os sentimentos, sendo o sentimento negativo duas vezes maior que o sentimento neutro, além do sentimento positivo ser quase duas vezes maior que o negativo. A Tabela 2 também conta com a média macro das métricas de precisão, *recall* e *F1 Score*, sendo calculada por meio de uma média simples entre os valores das métricas de cada sentimento; Ademais, também há a média ponderada, a qual atribui maior peso aos sentimentos de maior proporção no conjunto.

Logo, observa-se uma alta precisão para o sentimento positivo (97%) e uma precisão razoável para o sentimento negativo (82%), porém uma baixa precisão para o sentimento neutro (50%). No entanto, para a métrica de *recall*, vê-se que o sentimento negativo obteve maior *recall* (96%), ao passo que o sentimento positivo obteve o pior resultado (73%) e que o sentimento neutro obteve o segundo melhor resultado (79%). Já quanto a métrica de *F1 Score*, o sentimento melhor pontuado foi o negativo (89%), seguido pelo sentimento positivo (83%) e neutro (61%). Enfim, como média ponderada, tem-se uma precisão de 86%, *recall* de 81% e *F1 Score* de 81%; em contrapartida a uma média macro que apresenta uma precisão de 76%, *recall* de 83% e *F1 Score* de 78%.

Desse modo, destaca-se a boa inferência do sentimento negativo, compondo este uma proporção razoável de notícias (30,10%), assim como resultados razoáveis para o sentimento positivo, representando a maior parte das notícias (54,85%). Todavia, vê-se resultados menos satisfatórios para o sentimento neutro, que constitui, porém, a minoria das notícias (15,05%) e, portanto, afeta em menor medida a acurácia da solução proposta.

Contudo, é importante salientar que o sentimento tido como verdadeiro, por meio do processo de anotação apresentado no Capítulo 3, limita-se ao viés de conhecimento de mundo do autor deste trabalho de monografia, uma vez que 32 notícias (dentre 125) foram descartadas da avaliação. Assim, caso dispusesse-se de um número maior de anotadores humanos, poder-se-ia obter resultados distintos para com as métricas. Ainda, considerando o contexto das notícias analisadas por este trabalho, seria possível obter melhores resultados para as métricas por meio de um ajuste fino do LLM utilizado.

4.2 Visualizando os Sentimentos

A fim de gerar uma representação visual dos dados refinados por este trabalho de monografia, optou-se pelo Power BI Desktop, em que os dados utilizados para a geração de um *dashboard* foram obtidos via conexão ODBC com o AWS Athena. Assim, os dados contidos na tabela `refined_sentiment_news` da camada *refined* foram importados ao Power BI Desktop, culminando no *dashboard* representado pela Figura 8, a qual ilustra o índice de sentimentos da Petrobras de agosto a outubro de 2025.

Mais especificamente, o índice de sentimentos demonstra a oscilação diária do sentimento expressos pelo noticiário financeiro em relação as 87 empresas listadas no IBOVESPA. Ainda, o *dashboard* interativo permite selecionar a empresa de interesse agrupando-a por setor e subsetor, como também possibilita filtrar as oscilações de sentimentos por

Figura 8: Índice de Sentimentos da Petrobras

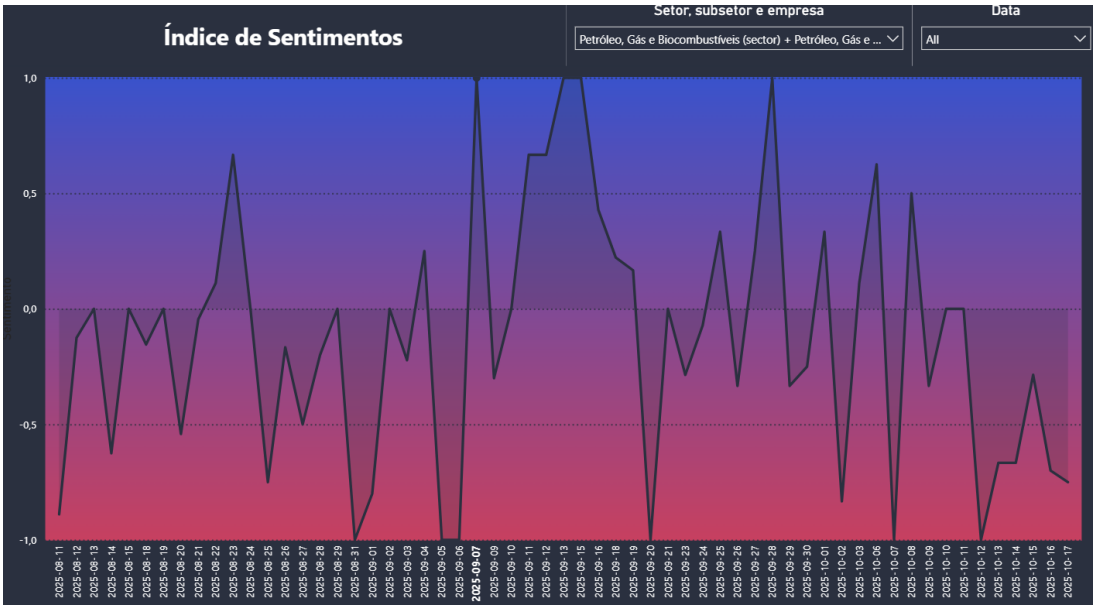

Fonte: Autoria Própria

ano, trimestre e mês. Logo, o índice de sentimentos varia entre o máximo valor positivo (1) e o máximo valor negativo (-1), em que o fundo do gráfico foi preenchido por um gradiente entre o azul (positivo) e o vermelho (negativo) para facilitar a visualização das oscilações de sentimento.

4.3 Custos da Aplicação

Com a Figura 9, tem-se os custos de desenvolvimento e implantação deste trabalho de monografia ao longo dos meses. Naturalmente, a medida que o trabalho foi sendo finalizado, a adição de novos recursos fez com que o custo mensal aumentasse. Entretanto, como referência de custo operacional para se manter o processo diário de extração, armazenamento, transformação e AS de notícias financeiras, tem-se o mês de novembro, em que apenas o processo operacional estava sendo executado. Já o salto de preço observado no mês de outubro se deu principalmente devido ao processo de anotação de notícias e, também, à avaliação da aplicação proposta.

Ainda, percebe-se que o maior custo está com o Amazon SageMaker, pois este representa todos os custos envolvendo o uso de Jupyter notebooks hospedados no AWS SageMaker Studio Lab, execução do LLM e utilização do *Ground Truth*. Desconsiderando, então, os custos envolvendo o *Ground Truth* e a avaliação da aplicação proposta, estima-se um custo mensal de 3 USD para manter as inferências do LLM utilizado.

Figura 9: Custos com AWS

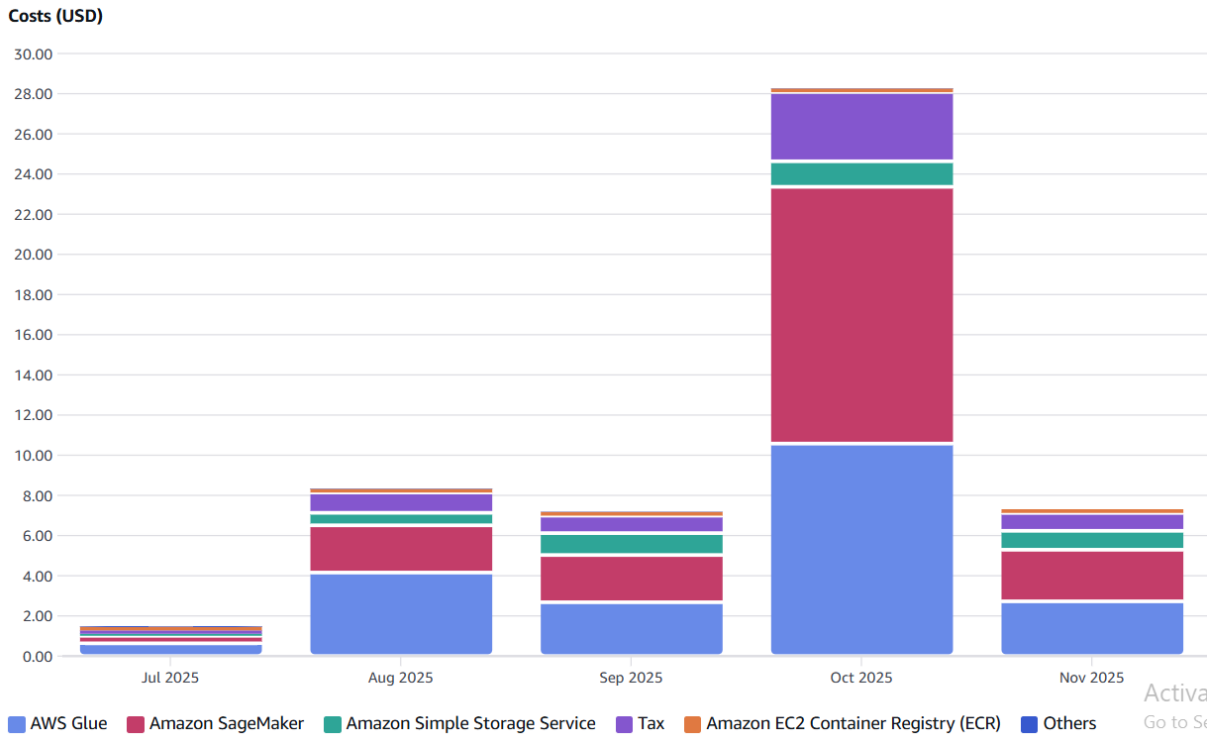

Fonte: Autoria Própria

Já quanto ao recurso de AWS Glue, este revela-se o segundo maior custo, mensalmente representando menos que 3 USD para executar os três AWS Glues criados para este trabalho de monografia. Ademais, o terceiro maior custo vem das taxas com 1 USD mensais. Em seguida está o AWS S3, custando em média 1 USD mensais para armazenar os dados deste trabalho. Enfim, todos os outros recursos tiveram custo zero, ou ínfimo, devido ao critério de *free tier*[1] da AWS, incluindo os recursos: AWS EventBridge, AWS Step Function, AWS Lambda, AWS Athena e AWS ECR.

Somando-se estes valores, estima-se um custo mensal de 8 USD para operar a aplicação, a qual permite a troca de processos caso necessário. Por exemplo, caso deseje-se aumentar a extração de notícias, bastaria alterar a lista de empresas de interesse que todos os processos seguiriam funcionando. Ainda, caso deseje-se adicionar uma nova fonte de notícias, bastaria criar um novo processo de extração o qual salvasse os dados na tabela `raw_news`, que todo o restante dos processos funcionariam sem nenhuma alteração. Outra alteração possível está na troca do LLM utilizado, caso deseje-se testar a aplicação proposta em outras línguas como o inglês.

[1] O critério de *free tier* da AWS representa uma cota ou crédito mensal, ou pontual, o qual isenta de custos a utilização de certos recursos da AWS até determinado limite mensal ou pontual.

5 CONCLUSÃO

Encerrando este trabalho de monografia, o presente capítulo discorre sobre as considerações gerais e contribuições obtidas, assim como comenta sobre as principais limitações e desafios enfrentados e conclui com as considerações finais e, também, com uma discussão sobre possíveis trabalhos futuros.

5.1 Considerações Gerais

Ao fim deste trabalho de monografia, pôde-se explorar diferentes processos que envolvem a engenharia de dados, tais como extração, armazenamento, transformação, análise e visualização de dados, de modo que estes processos fossem orquestrados e automatizados em uma lógica de execução diária.

Ainda, reitera-se que o maior tempo gasto durante o desenvolvimento deste trabalho deu-se nas primeiras etapas de extração e transformação dos dados, as quais formam o quotidiano de um(a) engenheiro(a) de dados, além de servirem de base para as etapas posteriores. Em outras palavras, quanto maior o esforço e empenho gastos nos processos de engenharia de dados, mais fácil se torna o trabalho de cientistas e analistas de dados.

5.2 Contribuições do Trabalho

Como contribuição, este trabalho apresenta uma demonstração detalhada de como automatizar processos que envolvam desde a extração até a análise de sentimentos de textos. Neste contexto, o mercado financeiro foi escolhido, porém a arquitetura desenvolvida poderia ser aplicada para qualquer tipo de texto ou contexto.

Ressaltando o valor obtido por meio da engenharia de dados aplicados neste trabalho, seria impossível obter-se uma análise de sentimentos discriminada por empresa caso o LLM utilizado fosse aplicado diretamente aos dados brutos presentes na camada *raw*.

5.3 Principais Limitações e Dificuldades

As principais limitações enfrentadas por este trabalho de monografia se resguardam à ausência de validação especializada sobre o mercado financeiro. Isto é, caso dispusesse-se de uma pessoa qualificada para determinar quais veículos de comunicação são mais confiáveis e informativos, reduzir-se-ia as chances de indução ao erro. Logo, sem esta validação, casos como o de notícias repetidas oriundas de uma fonte comum, assim como o de notícias publicadas por veículos de comunicação tendenciosos, podem induzir a uma análise favorável a uma empresa, quando a realidade pode ser o total oposto.

Ademais, mesmo que o presente trabalho tenha organizado todos os recursos utilizados de modo facilmente reproduzível entre contas AWS, isto também representa uma dependência tecnológica. Por outro lado, a confiabilidade quanto a provedores de infraestrutura em nuvem tem sido questionada devido aos frequentes incidentes, destacando-se o episódio de 20 de outubro de 2025, em que um incidente na AWS culminou em mais de mil serviços e *sites* fora de funcionamento.

Logo, visando uma melhor replicabilidade, a escolha por soluções *open source*, como o Apache AirFlow, poderiam ser explorados para orquestrar e processar os dados, uma vez que este tipo de solução normalmente possui suporte para diferentes provedores de computação em nuvem, além de poderem ser implantados em ambientes *on-premises*.

5.4 Considerações Finais

Ao fim deste trabalho de monografia, obteve-se uma aplicação capaz de extrair, transformar, armazenar, analisar e refinar dados respeitando uma organização em camadas, o que facilita o processo de desenvolvimento de produtos de dados. Mais precisamente, produtos de dados são tabelas, modelos, análises e afins apenas tangíveis a partir da engenharia de dados, a qual extrai e transforma dados brutos em cofiáveis, fomentando a criação de produtos de dados por cientistas e analistas de dados.

Contudo, este trabalho de monografia se encontra aquém de representar uma solução definitiva para decifrar o mercado acionário, devido sua natureza multifatorial inerente às oscilações das ações. Desta forma, este trabalho se propõe como uma prova de conceito sobre como automatizar a análise sentimentos de notícias financeiras, o que representa apenas um dos muitos fatores que exercem influência sobre o mercado acionário.

5.5 Trabalhos Futuros

Ademais, uma vez estando os dados organizados em camadas logicas e distintas, bem como estando o processamento destes dados desatrelado do armazenamento, isto é, não sendo este trabalho realizado em um monólito, facilita-se o planejamento de melhorias, evoluções e trabalhos futuros.

Neste sentido, almejando-se melhores métricas para com a AS das notícias, poder-se-ia automatizar o agendamento do processo de anotação de notícias e, posteriormente, a avaliação da aplicação proposta, ao passo que caso fosse identificado uma piora nas métricas, seria possível automatizar o ajuste fino do LLM utilizado.

Outra melhoria está na adoção de uma estratégia de seleção de amostras significativas para a anotação de notícias. Assim, ao invés de aleatoriamente selecionar-se notícias para realizar o ajuste fino do LLM utilizado, selecionar-se-iam notícias mais significativas por meio de algoritmos de aprendizado não supervisionado, reduzindo o esforço humano e aumentando a acurácia do modelo.

Por fim, outra melhoria poderia vir do aumento da quantidade de notícias analisadas ao considerar notícias com múltiplas empresas mencionadas. Isto significaria desenvolver uma estratégia de AS baseada em aspectos, ou seja, atrelar um sentimento para cada empresa mencionada em uma notícia.

REFERÊNCIAS

ALAMMAR, J.; GROOTENDORST, M. **Hands-on large language models**. Sebastopol, CA: O'Reilly Media, 2024. ISBN 9781098150938. Disponível em: <https://books.google.com.br/books?id=iE8hEQAAQBAJ>.

ASHTIANI, M. N.; RAAHEMI, B. **News-based intelligent prediction of financial markets using text mining and machine learning: A systematic literature review**. Elsevier Ltd, 2023. Disponível em: <https://doi.org/10.1016/j.eswa.2023.119509>.

BRUCE, P.; BRUCE, A.; GEDECK, P. **Practical Statistics for Data Scientists: 50+ Essential Concepts Using R and Python**. Sebastopol, CA: O'Reilly Media, 2020. ISBN 9781492072898. Disponível em: <https://books.google.com.br/books?id=F2bcDwAAQBAJ>.

CAI, T.; YU, B.; XU, W. Transformer-based bilstm for aspect-level sentiment classification. **2021 4th International Conference on Robotics, Control and Automation Engineering, RCAE 2021**, Institute of Electrical and Electronics Engineers Inc., p. 138–142, 2021. Disponível em: <https://doi.org/10.1109/RCAE53607.2021.9638807>.

CHAHAR, R.; DUBEY, A. K. Machine learning-based sentiment analysis: A comprehensive review. **2024 International Conference on Cognitive Robotics and Intelligent Systems, ICC - ROBINS 2024**, Institute of Electrical and Electronics Engineers Inc., p. 52–57, 2024. Disponível em: <https://doi.org/10.1109/ICC-ROBINS60238.2024.10533989>.

CHOWDHARY, K. **Fundamentals of Artificial Intelligence**. Springer India, 2020. ISBN 9788132239727. Disponível em: <https://books.google.com.br/books?id=8SfbDwAAQBAJ>.

DEVLIN, J.; CHANG, M. W.; LEE, K.; TOUTANOVA, K. Bert: Pre-training of deep bidirectional transformers for language understanding. **NAACL HLT 2019 - 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies - Proceedings of the Conference**, Association for Computational Linguistics (ACL), v. 1, p. 4171–4186, 10 2018. Disponível em: <https://arxiv.org/pdf/1810.04805>.

DUAN, G.; YAN, S.; ZHANG, M. A hybrid neural network model for sentiment analysis of financial texts using topic extraction, pre-trained model, and enhanced attention mechanism methods. **Institute of Electrical and Electronics Engineers (IEEE)**, Institute of Electrical and Electronics Engineers Inc., v. 12, p. 98207–98224, 2024. ISSN 21693536. Disponível em: <https://doi.org/10.1109/ACCESS.2024.3429150>.

FAYYAD, U.; PIATETSKY-SHAPIRO, G.; SMYTH, P. From data mining to knowledge discovery in databases. **AI Magazine**, v. 17, n. 3, p. 37, Mar. 1996. Disponível em: <https://ojs.aaai.org/index.php/aimagazine/article/view/1230>.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A.; BENGIO, Y. **Deep learning**. 1. ed. Londres, Inglaterra: MIT Press, 2016. v. 1. (Adaptive Computation and Machine Learning series, v. 1). ISBN 9780262035613. Disponível em: <https://books.google.com.br/books?id=Np9SDQAAQBAJ>.

GéRON, A. **Hands-On Machine Learning with Scikit-Learn and PyTorch**. Sebastopol, CA: O'Reilly Media, 2025. ISBN 9798341607989. Disponível em: <https://books.google.com.br/books?id=50Q50QEACAAJ>.

HEVNER; MARCH; PARK; RAM. Design science in information systems research. **MIS Quarterly**, MIS Quarterly, v. 28, n. 1, p. 75, 2004. ISSN 0276-7783. Disponível em: <http://dx.doi.org/10.2307/25148625>.

HUANG, Y.; LIN, R.; LI, J.; LI, Y.; CHEN, J.; LIANG, J.; FENG, G.; LV, J. A finbert framework for sentiment analysis of chinese financial news. In: **2024 4th International Symposium on Computer Technology and Information Science, ISCTIS 2024**. Institute of Electrical and Electronics Engineers Inc., 2024. p. 796–799. ISBN 9798350354560. Disponível em: <https://doi.org/10.1109/ISCTIS63324.2024.10699096>.

JIN, X.; CHEN, C.; YANG, X. The effect of international media news on the global stock market. **International Review of Economics and Finance**, Elsevier Inc., v. 89, p. 50–69, 1 2024. ISSN 10590560. Disponível em: <https://doi.org/10.1016/j.iref.2023.07.096>.

KOKAB, S. T.; ASGHAR, S.; NAZ, S. Transformer-based deep learning models for the sentiment analysis of social media data. **Array**, Elsevier B.V., v. 14, 7 2022. ISSN 25900056. Disponível em: <https://doi.org/10.1016/j.array.2022.100157>.

LANE, H.; DYSHEL, M. **Natural Language Processing in Action, Second Edition**. New York, NY: Manning, 2025. (In Action). ISBN 9781617299445. Disponível em: <https://books.google.com.br/books?id=hBRDEQAAQBAJ>.

LO, A. W. The adaptive markets hypothesis. **The Journal of Portfolio Management**, With Intelligence LLC, v. 30, n. 5, p. 15–29, jan. 2004. ISSN 2168-8656. Disponível em: <http://dx.doi.org/10.3905/jpm.2004.442611>.

MAO, Y.; LIU, Q.; ZHANG, Y. Sentiment analysis methods, applications, and challenges: A systematic literature review. **Journal of King Saud University - Computer and Information Sciences**, v. 36, n. 4, p. 102048, 2024. ISSN 1319-1578. Disponível em: <https://www.sciencedirect.com/science/article/pii/S131915782400137X>.

PEFFERS, K.; TUUNANEN, T.; ROTHENBERGER, M. A.; CHATTERJEE, S. A design science research methodology for information systems research. **Journal of Management Information Systems**, Routledge, v. 24, n. 3, p. 45–77, 2007. Disponível em: <https://doi.org/10.2753/MIS0742-1222240302>.

PETTER, M. M. T. Linguagem, língua, lingüística. In: FIORIN, J. L. (Ed.). **Introdução à linguística: objetos teóricos**. 6. ed. São Paulo: Contexto, 2002, (Introdução a linguística, v. 1). p. 11–24. ISBN 8572441921.

RAY, P. P. Chatgpt: A comprehensive review on background, applications, key challenges, bias, ethics, limitations and future scope. **Internet of Things and Cyber-Physical Systems**, Elsevier, v. 3, p. 121–154, 1 2023. ISSN 2667-3452. Disponível em: <https://www.sciencedirect.com/science/article/pii/S266734522300024X>.

SANTOS, L.; BIANCHI, R.; COSTA, A. Finbert-pt-br: Análise de sentimentos de textos em português do mercado financeiro. In: **Anais do II Brazilian Workshop on Artificial Intelligence in Finance**. Porto Alegre, RS, Brasil: Sociedade Brasileira de Computação, 2023. p. 144–155. ISSN 2965-9728. Disponível em: <https://sol.sbc.org.br/index.php/bwaif/article/view/24960>.

SERRA, J. **Decifrando Arquiteturas de Dados: Escolhendo entre data warehouse moderno, data fabric, data lakehouse e data mesh**. Novatec Editora, 2024. ISBN 9788575229217. Disponível em: <https://books.google.com.br/books?id=Gd4aEQAAQBAJ>.

SOLAIMAN, S.; RAHMAN, B. M.; AREFIN, M. F.; AHMED, C. F.; LEUNG, C. K.; MADILL, E. W. Unveiling market sentiments: A comprehensive analysis of stock market responses to diverse news events using data mining techniques. In: **Proceedings of the 2024 18th International Conference on Ubiquitous Information Management and Communication, IMCOM 2024**. Institute of Electrical and Electronics Engineers (IEEE), 2024. p. 1–8. ISBN 9798350331011. Disponível em: <https://doi.org/10.1109/IMCOM60618.2024.10418389>.

SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: Pretrained BERT models for brazilian portuguese. In: CERRI, R.; PRATI, R. C. (Ed.). **Intelligent Systems: 9th Brazilian Conference, BRACIS 2020, Rio Grande, Brazil, October 20-23, 2020, Proceedings**. Cham: Springer International Publishing, 2020. (Lecture Notes in Computer Science, v. 12319), p. 403–417. ISBN 978-3-030-61377-8. Disponível em: <http://dx.doi.org/10.1007/978-3-030-61377-8_28>.

SUDHA, K.; MUTHUMARILAKSHMI, S.; KAVITHA, G.; S, H.; KUMAR, V. N.; R, S. S. Sentiment analysis on text data: Methods, applications, challenges and future directions. In: **2023 International Conference on Evolutionary Algorithms and Soft Computing Techniques (EASCT)**. Institute of Electrical and Electronics Engineers (IEEE), 2023. p. 1–7. Disponível em: <http://dx.doi.org/10.1109/EASCT59475.2023.10392868>.

TUNSTALL, L.; WERRA, L. von; WOLF, T. **Natural Language Processing with Transformers, Revised Edition**. O'Reilly Media, 2022. ISBN 9781098136765. Disponível em: <https://books.google.com.br/books?id=9JlxEAAAQBAJ>.

VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, L.; POLOSUKHIN, I. **Attention Is All You Need**. arXiv, 2017. Disponível em: <https://arxiv.org/abs/1706.03762>.

WILLIAMS, J. G.; HUANG, Z. **Modeling the KDD process A four stage and four elements model**. Canberra, ACT, Australia, 1996. Disponível em: <https://www.researchgate.net/publication/242376693_Modelling_the_KDD_Process_A_Four_Stage_Process_and_Four_Element_Model>.